CLOUD NATIVE
COMPUTING FOUNDATION

Slurm-on-K8s For AI Platform

Adaptive HPC Scheduling on
Cloud Native Infrastructure
For AI Batch Job

2025.04.30

Agenda

1. Introduction
2. System Architecture
3. Demo & Evaluation
4. References

01. Introduction

專題簡介

Example Scenarios

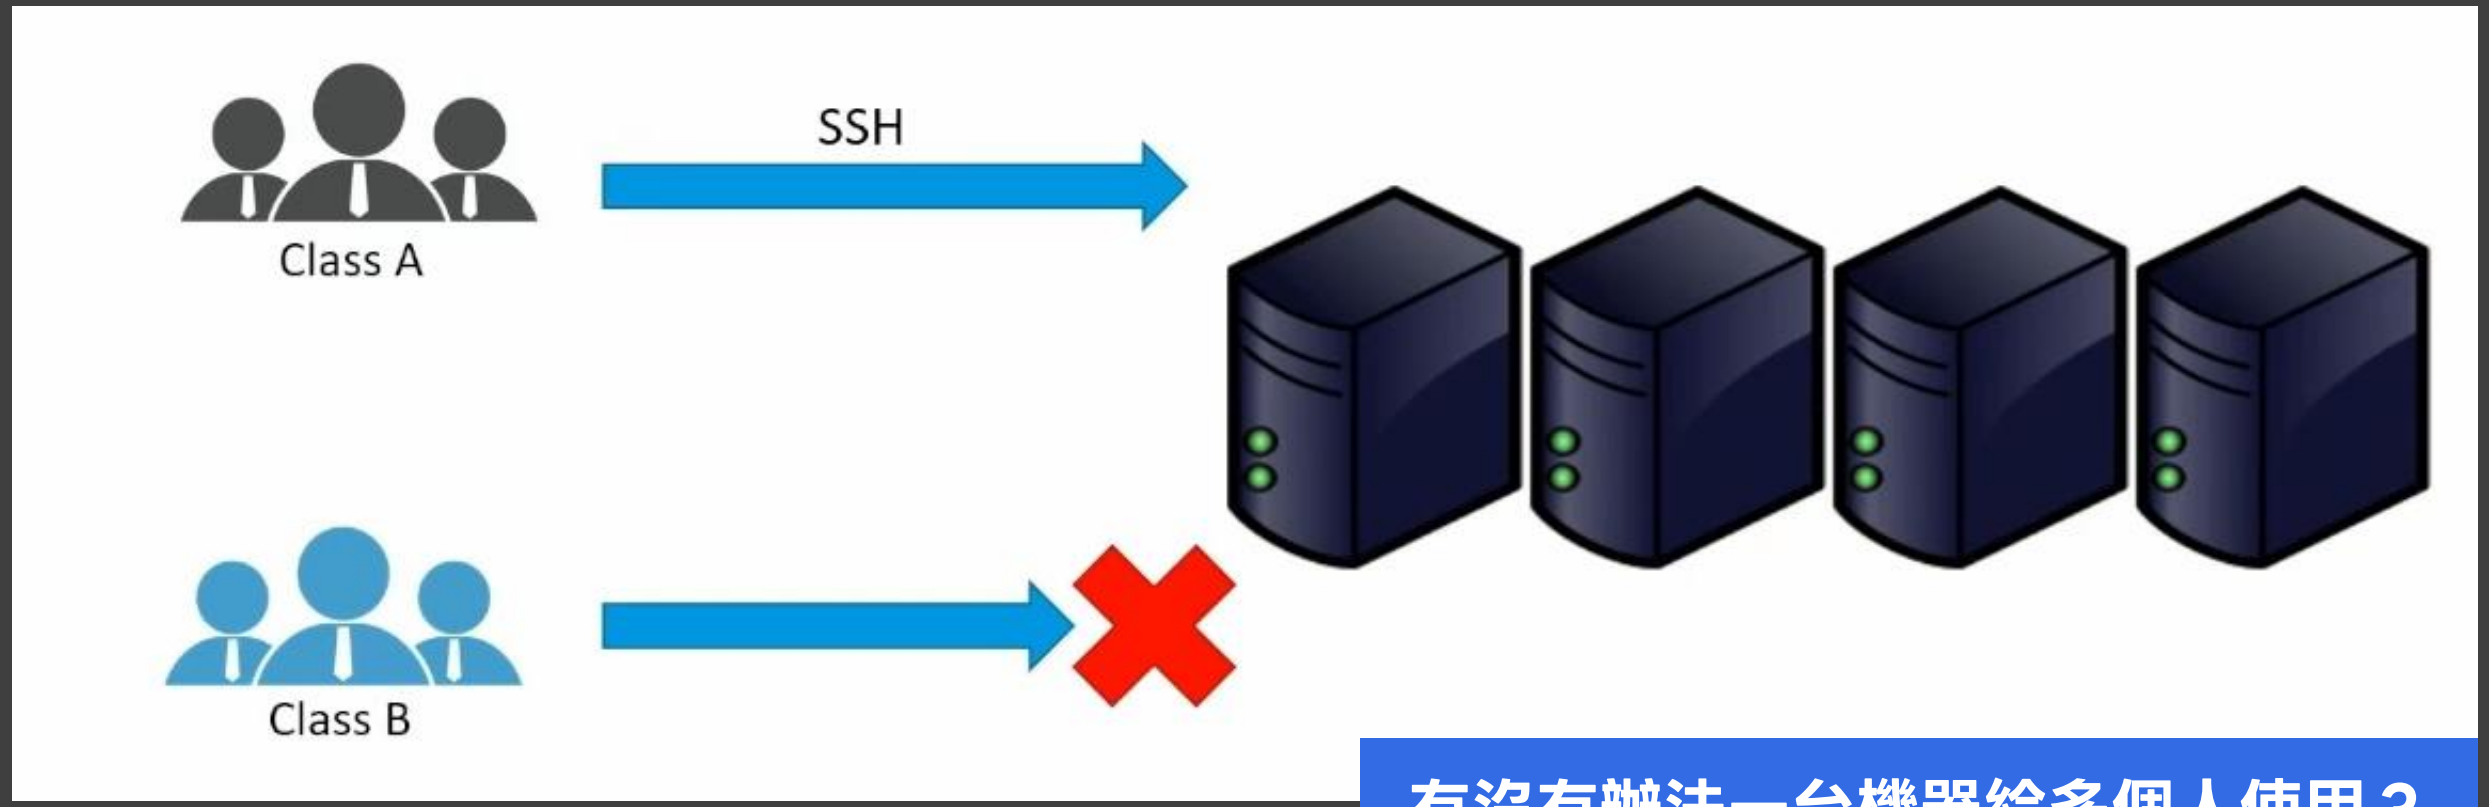

有沒有辦法一台機器給多個人使用？

Example Scenarios

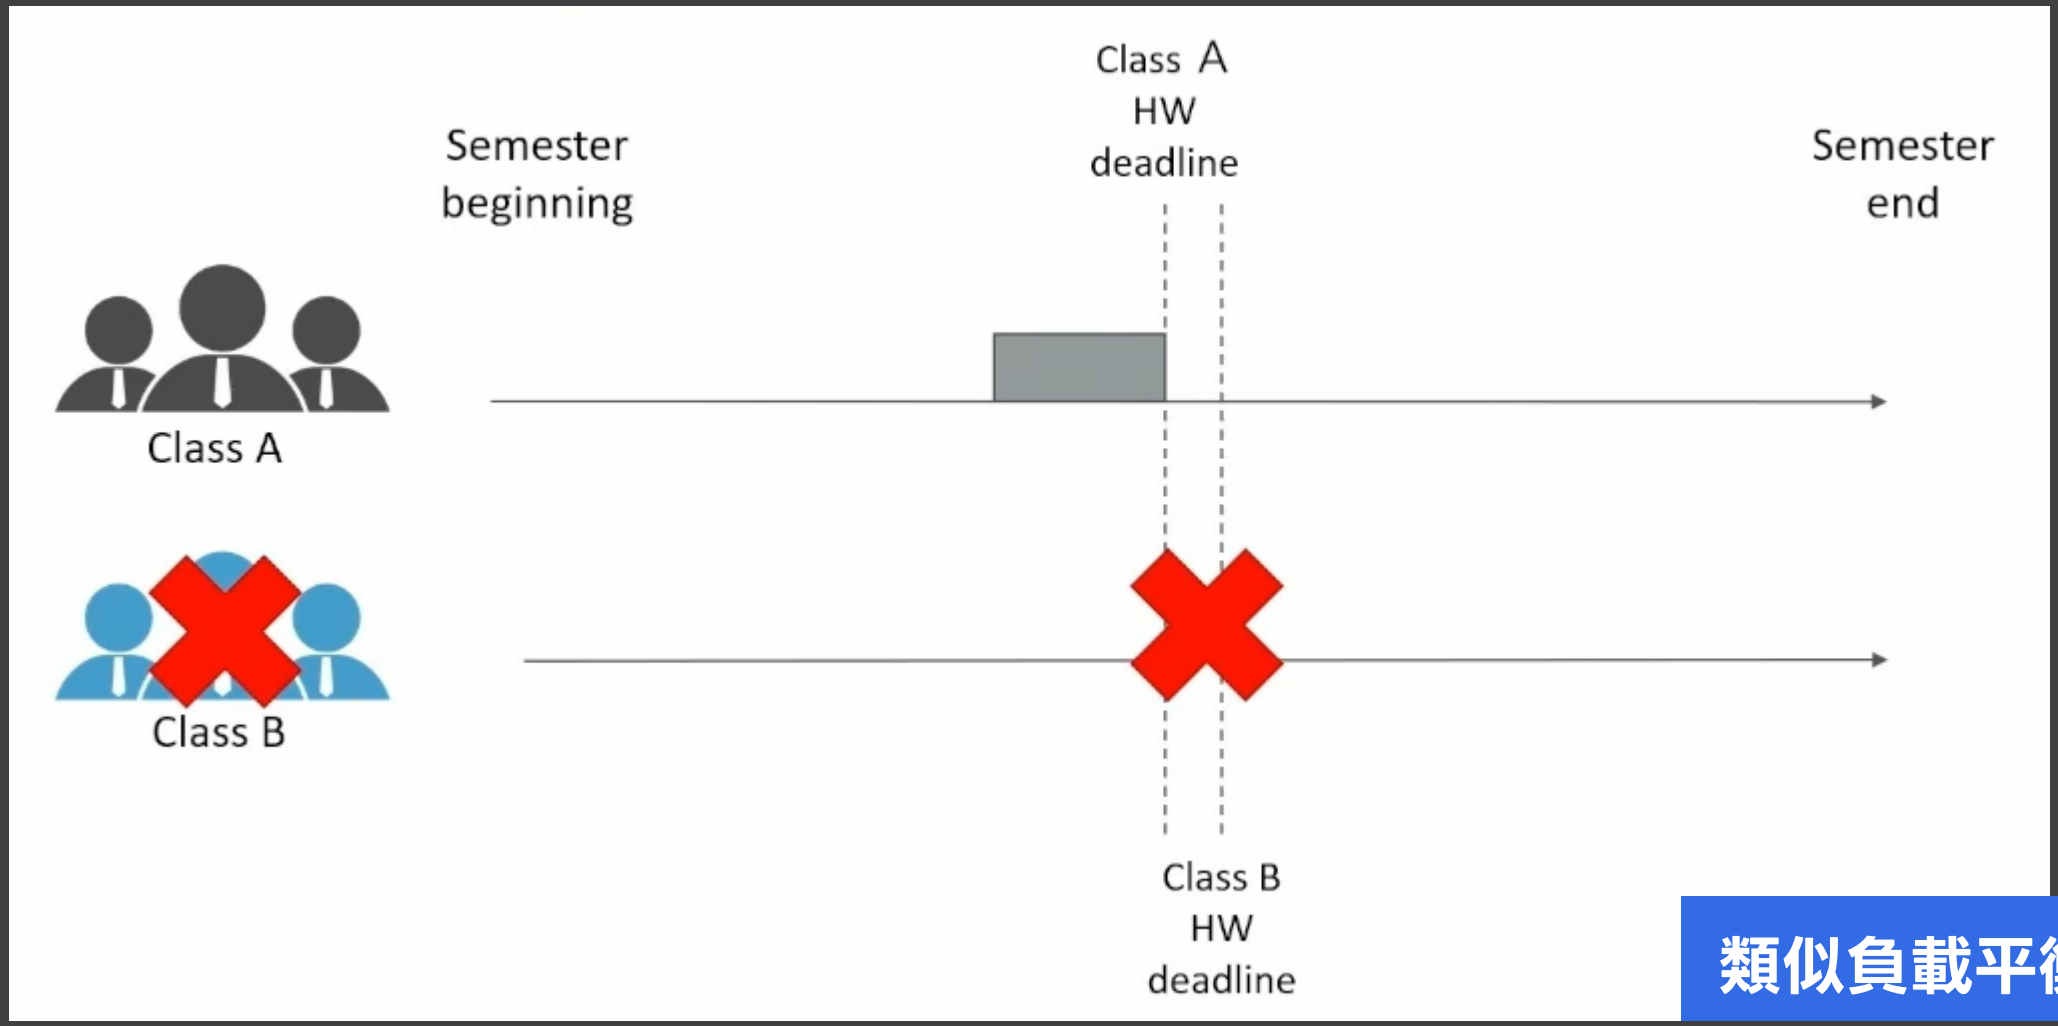

類似負載平衡的概念

Slurm

What is Slurm？

- Slurm = Simple Linux Utility for Resource Management
- An open source system
  - 管理工作：資料分配、排程、執行

Roles in Slurm

- Login nodes = 接待員/客服
- Controller = 主管
- Compute nodes = 工人
- DB interface = 會計師

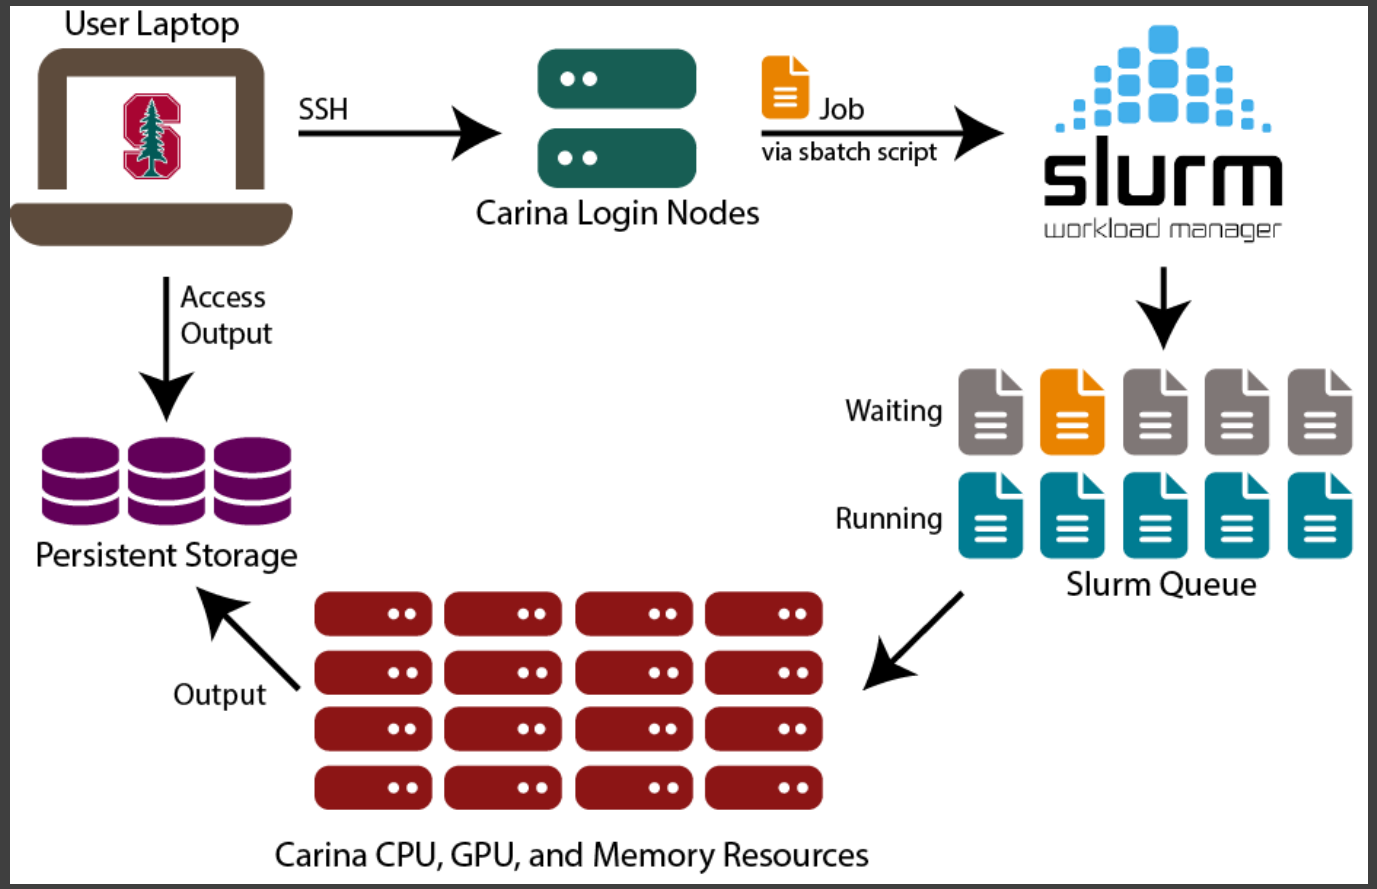

Running a job in Slurm (srun)

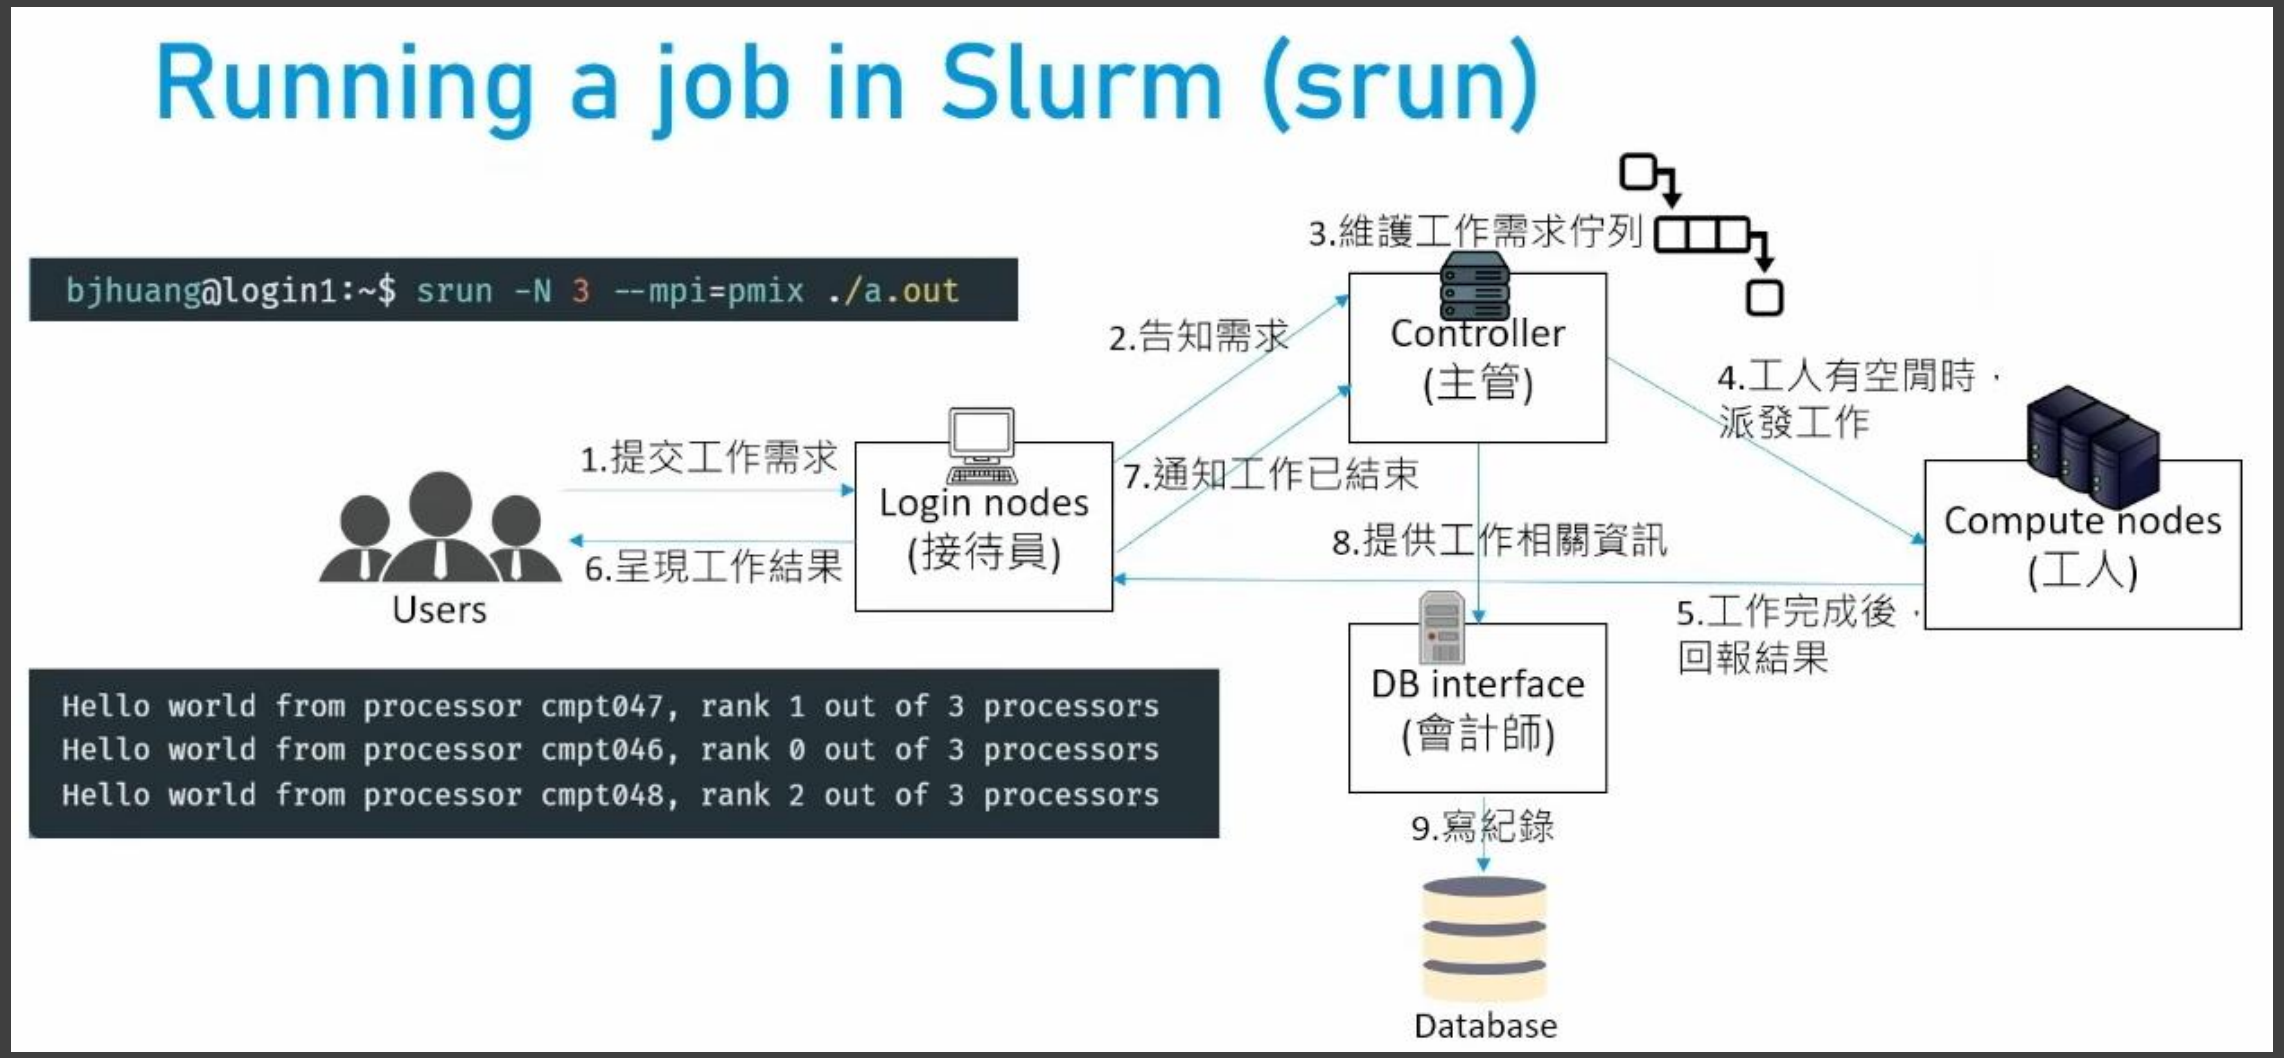

Kubernetes

What is Kubernetes？

- Kubernetes (K8s) = Containers Orchestration Tool
- An open source system
  - 管理容器：啟動、運算資源、排程、自動部署
  - 大公司架設服務很愛用

Kubernetes Distribution

- 本來是用 kind，但硬體支援度有極限，改成使用 K3s
- 建立在 Kubernetes 標準安裝之上的一個輕量發行版
- 由 Rancher Labs 開發，通過 CNCF 認證。

K3s

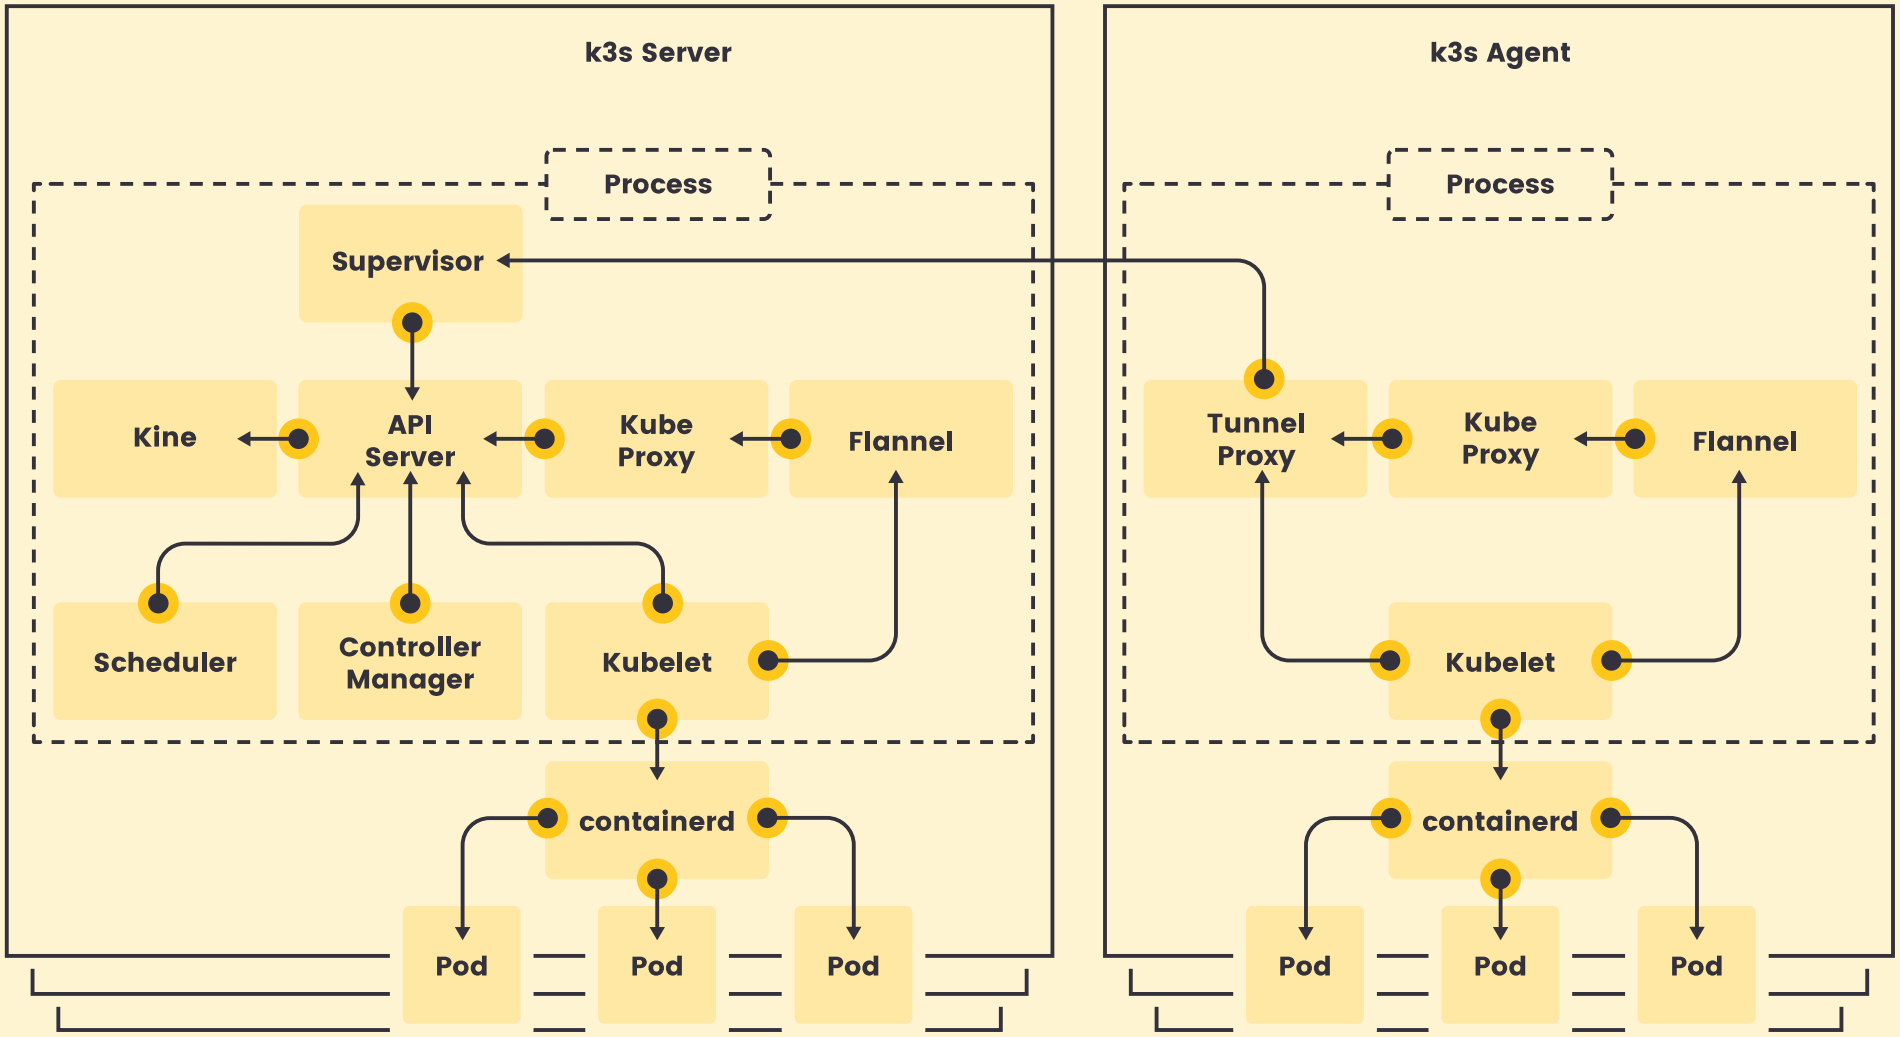
k3s Server
Process
Supervisor
Kine
API Server
Kube Proxy
Flannel
Scheduler
Controller Manager
Kubelet
containerd
Pod
Pod
Pod
k3s Agent
Process
Tunnel Proxy
Kube Proxy
Flannel
Kubelet
containerd
Pod
Pod
Pod

Background

Motivation

- Kubernetes 很擅長資源編排與彈性伸縮，但對 HPC / AI 訓練工作負載的語意支援有限。
- Slurm 很擅長批次排程、資源配額與叢集治理，但傳統部署通常偏靜態，對雲端環境的節點生命週期不夠友善。

⟹ 打造一個讓多位使用者共用的批次 AI 工作平台

Benefits

- 提升資源利用率
  - Slurm 可以透過將工作排程到 K8s 叢集中的可用資源
- 簡化的工作負載管理
  - 一律透過 Slurm 介面，用於管理 ML 工作負載
- 提升可擴展性
  - Slurm 可以透過將機器學習工作負載排程到多個 K8s 叢集來擴展

Slurm on Kubernetes

- Slurm 決定誰用資源、什麼時候用、用多少
  - 計算資源排程問題
- Kubernetes 決定資源怎麼存在、怎麼啟動、怎麼管理
  - 動態提供 Slurm 需要的運算節點
  - 當硬體調整的時候不用重新調整 Slurm 設定
  - 依賴版本管理、網路設定

Our Feature !

- 擴容、擴縮、低功耗、節點壞掉重啟
- 客製化排程演算法、運算資源分配
- 支援多種 Job
- 近年來企業很重視安全，可以裝個龍蝦
- Checkpoint Guard

Reliability

Performance

Lifecycle Unity

Observability

02.
System Architecture

系統設計與架構

Development Environment

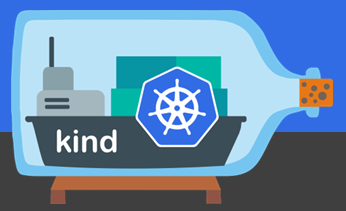

- Ubuntu 24.04 + K3s + RTX 4070
- Operator：Python 3.11-slim + kubectl CLI

https://kind.sigs.k8s.io/

Slurm GRES

- Slurm 的通用資源管理機制，讓 Slurm 能夠追蹤和排程 CPU/Memory 以外的資源 (e.g. GPU)
- 知道每個 node 上有哪些 GPU（型號、數量）
- 讓使用者提交 job 時指定需要的 GPU 類型和數量
- 確保 GPU 資源不會被過度分配

https://slurm.schedmd.com/gres.html | https://hackmd.io/iLGwBiBSTEeJYbw0fVXprw?view

GPU Resources

Multi-Process Service (MPS)

- 在 GPU 上創建多個 context，將 GPU 的資源分配給多個 process
- 每個進程擁有一個獨立的 context，可以獨立執行其計算任務，仿佛擁有獨立的 GPU。
- Linux-specific
- 可以提升推論速度

https://docs.nvidia.com/deploy/mps/index.html | https://ithelp.ithome.com.tw/m/articles/10366226

Multi-Process Service (MPS)

- 目前正在研究 nvidia-device-plugins 哪個版本可以正常用 MPS
- 暫時用 time-slicing 替代

https://docs.nvidia.com/deploy/mps/index.html | https://ithelp.ithome.com.tw/m/articles/10366226

Observability

Observability

雲端服務崛起

錯誤排查難度上升

Observability

Slurm	Bridge	K8s
Queue depth	Operator scale decision	StatefulSet replicas
Job wait-time	Scale-up event	Pod ready time
Node idle-time	Scale-down decision	Replica count drop
Checkpoint age	Guard blocked / allowed	Scale event skipped

Prometheus

- 最受歡迎的開源監控與告警工具組，是 CNCF 的畢業專案
- 專為動態雲端環境設計，擅長透過 HTTP 拉取模型收集指標，儲存於時間序列資料庫中，並使用 PromQL 進行數據查詢分析。
- 負責發 Alert 到 Slack/Telegram

https://wade-software-study-note.medium.com/devops%E8%AA%B2%E7%A8%8B-prometheus-1-7a690f7d4426

Grafana

- 能夠將各種資料做成監控儀表板，支援多種資料來源，以及提供豐富的面板選擇，協助我們將資料視覺化。
- Prometheus 預設的 GUI 功能不足，需要 Grafana 這種支援豐富圖表的工具幫助我們可視化 Metrics 資訊。

https://www.figma.com/deck/O8BwdzmRUfedbq0s8w7gm8/sitcon2026-grafana-v3?node-id=21-158

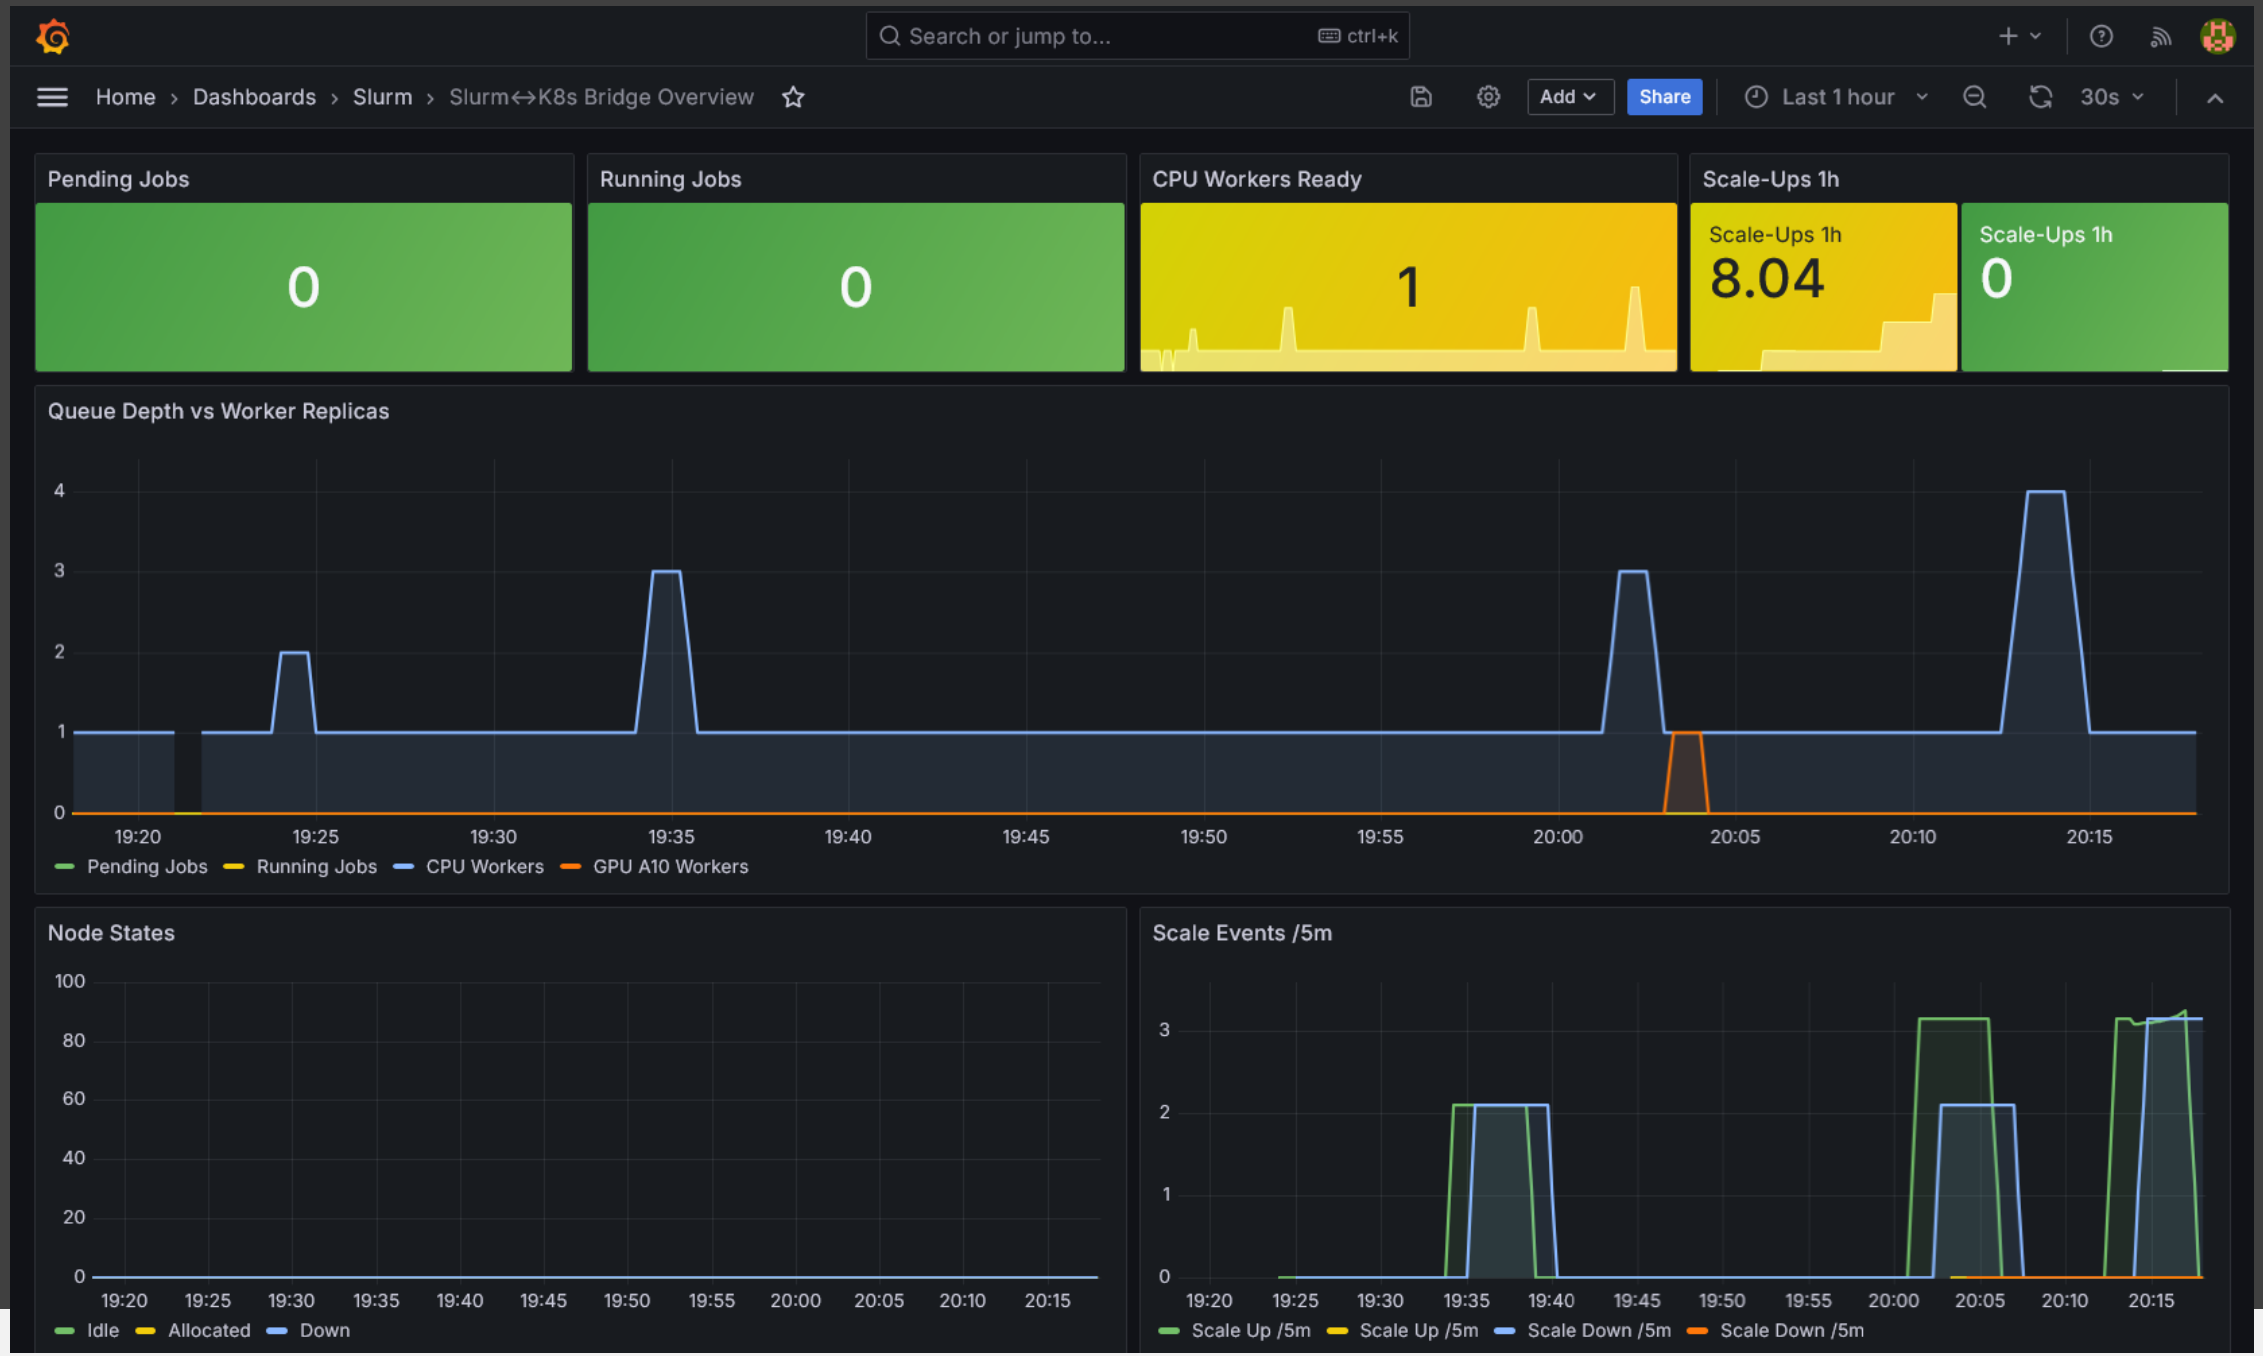
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › Slurm↔K8s Bridge Overview
Add
Share
Last 1 hour
30s
Pending Jobs
0
Running Jobs
0
CPU Workers Ready
1
Scale-Ups 1h
Scale-Ups 1h
8.04
Scale-Ups 1h
0
Queue Depth vs Worker Replicas
4
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Pending Jobs
Running Jobs
CPU Workers
GPU A10 Workers
Node States
100
80
60
40
20
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Idle
Allocated
Down
Scale Events /5m
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Scale Up /5m
Scale Up /5m
Scale Down /5m
Scale Down /5m

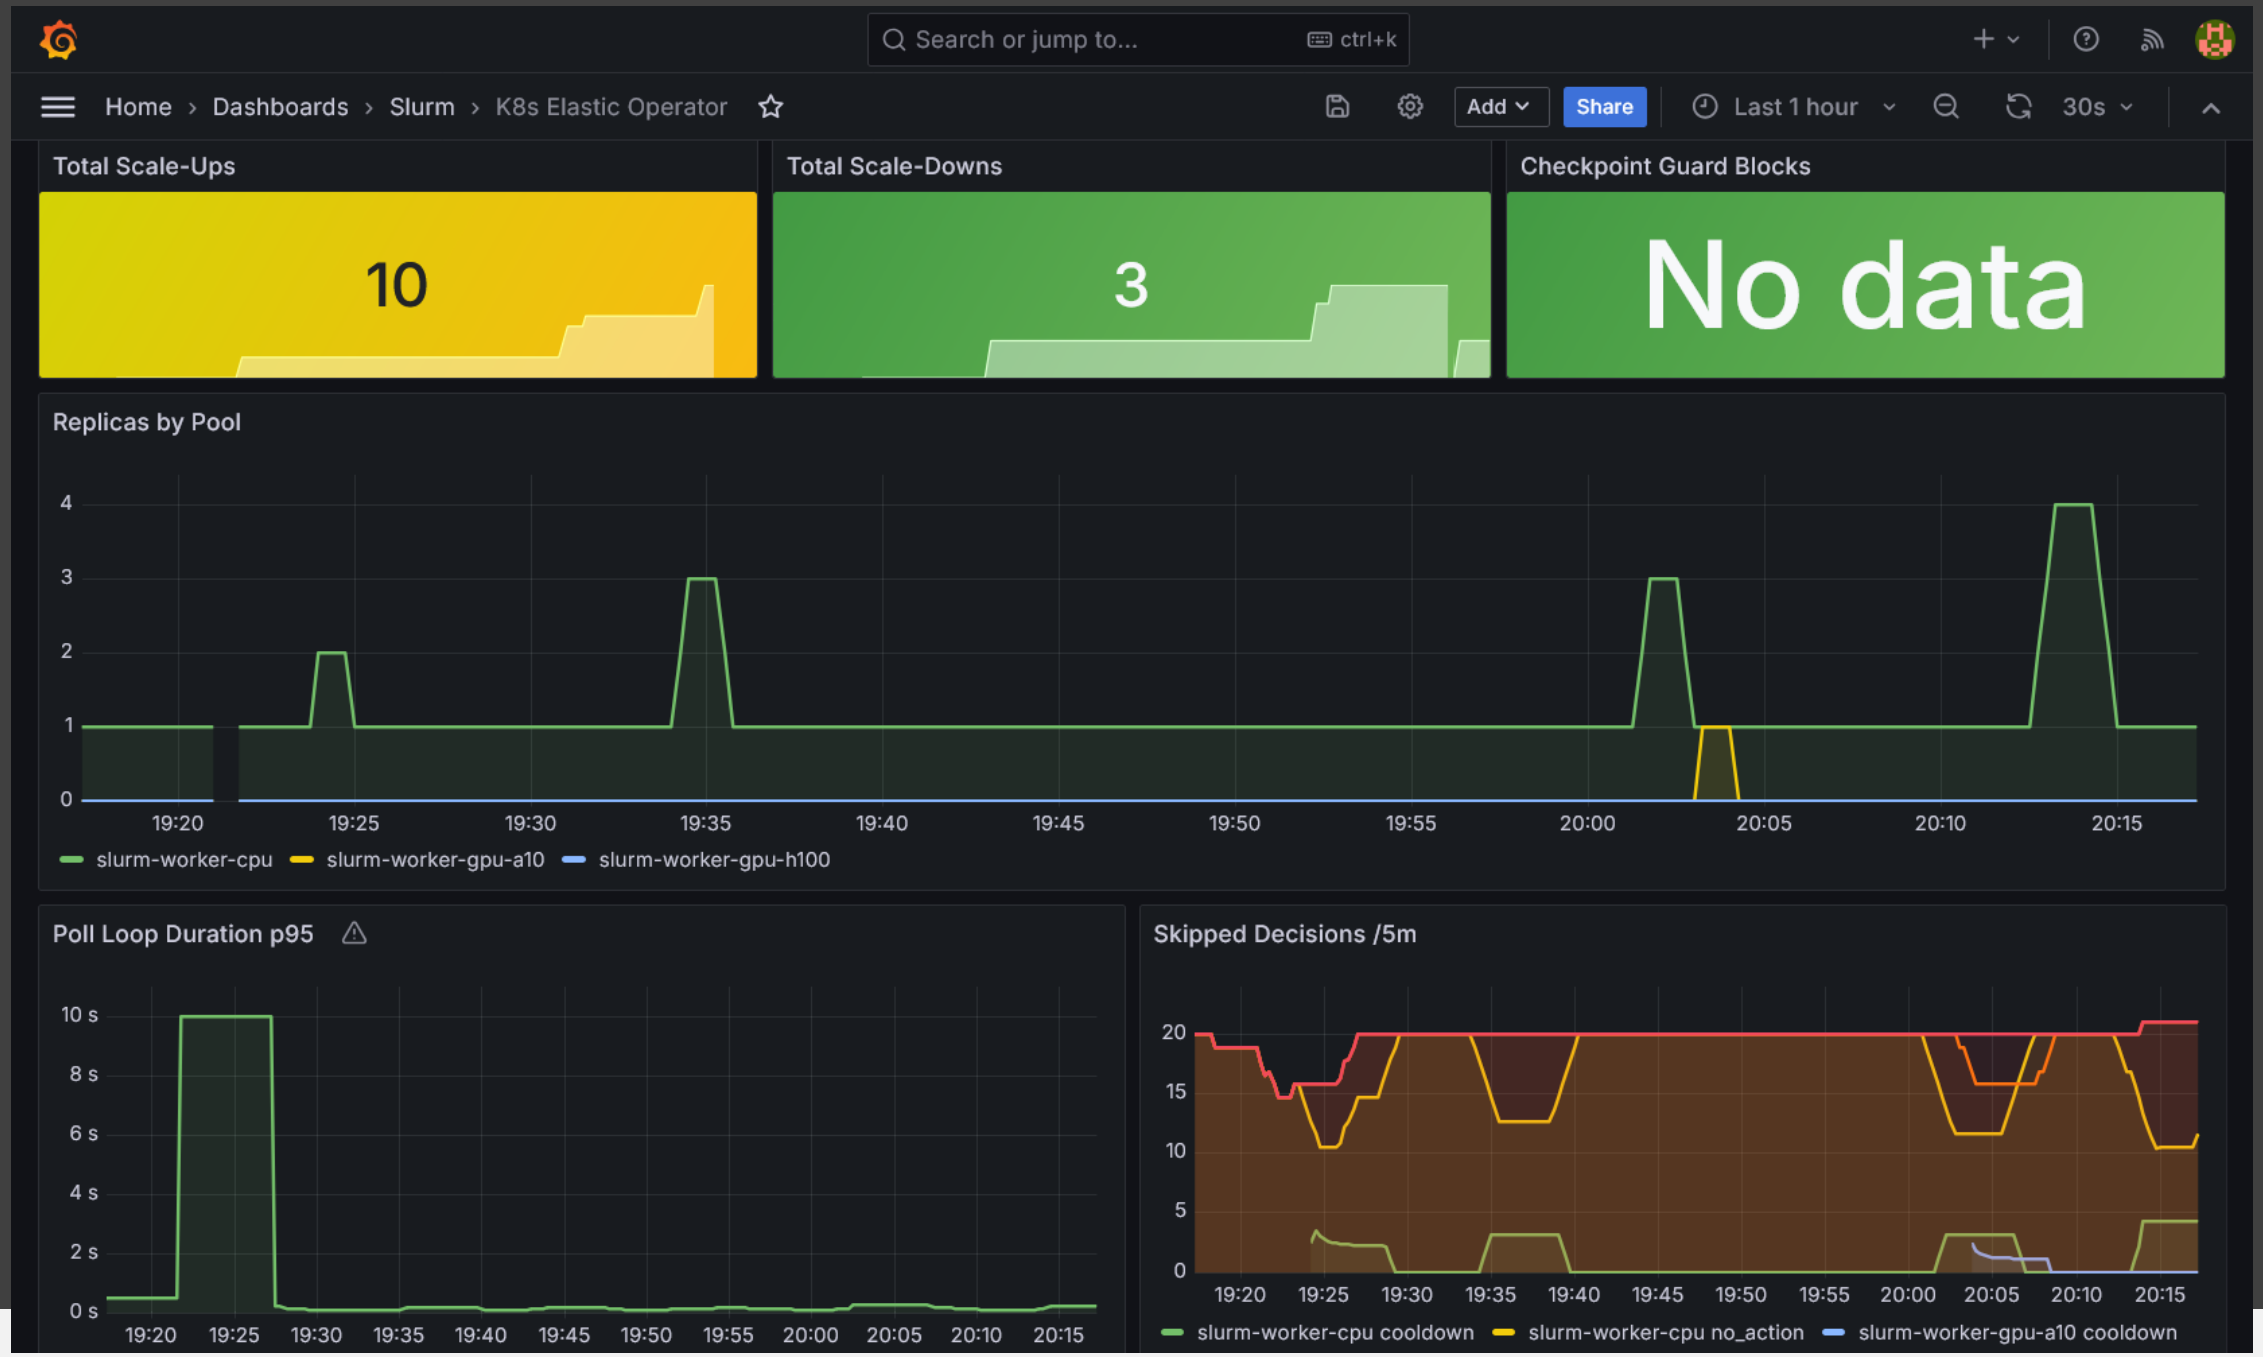
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › K8s Elastic Operator
Add
Share
Last 1 hour
30s
Total Scale-Ups
10
Total Scale-Downs
3
Checkpoint Guard Blocks
No data
Replicas by Pool
4
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
slurm-worker-cpu
slurm-worker-gpu-a10
slurm-worker-gpu-h100
Poll Loop Duration p95
10 s
8 s
6 s
4 s
2 s
0 s
Skipped Decisions /5m
20
15
10
5
0
slurm-worker-cpu cooldown
slurm-worker-cpu no_action
slurm-worker-gpu-a10 cooldown

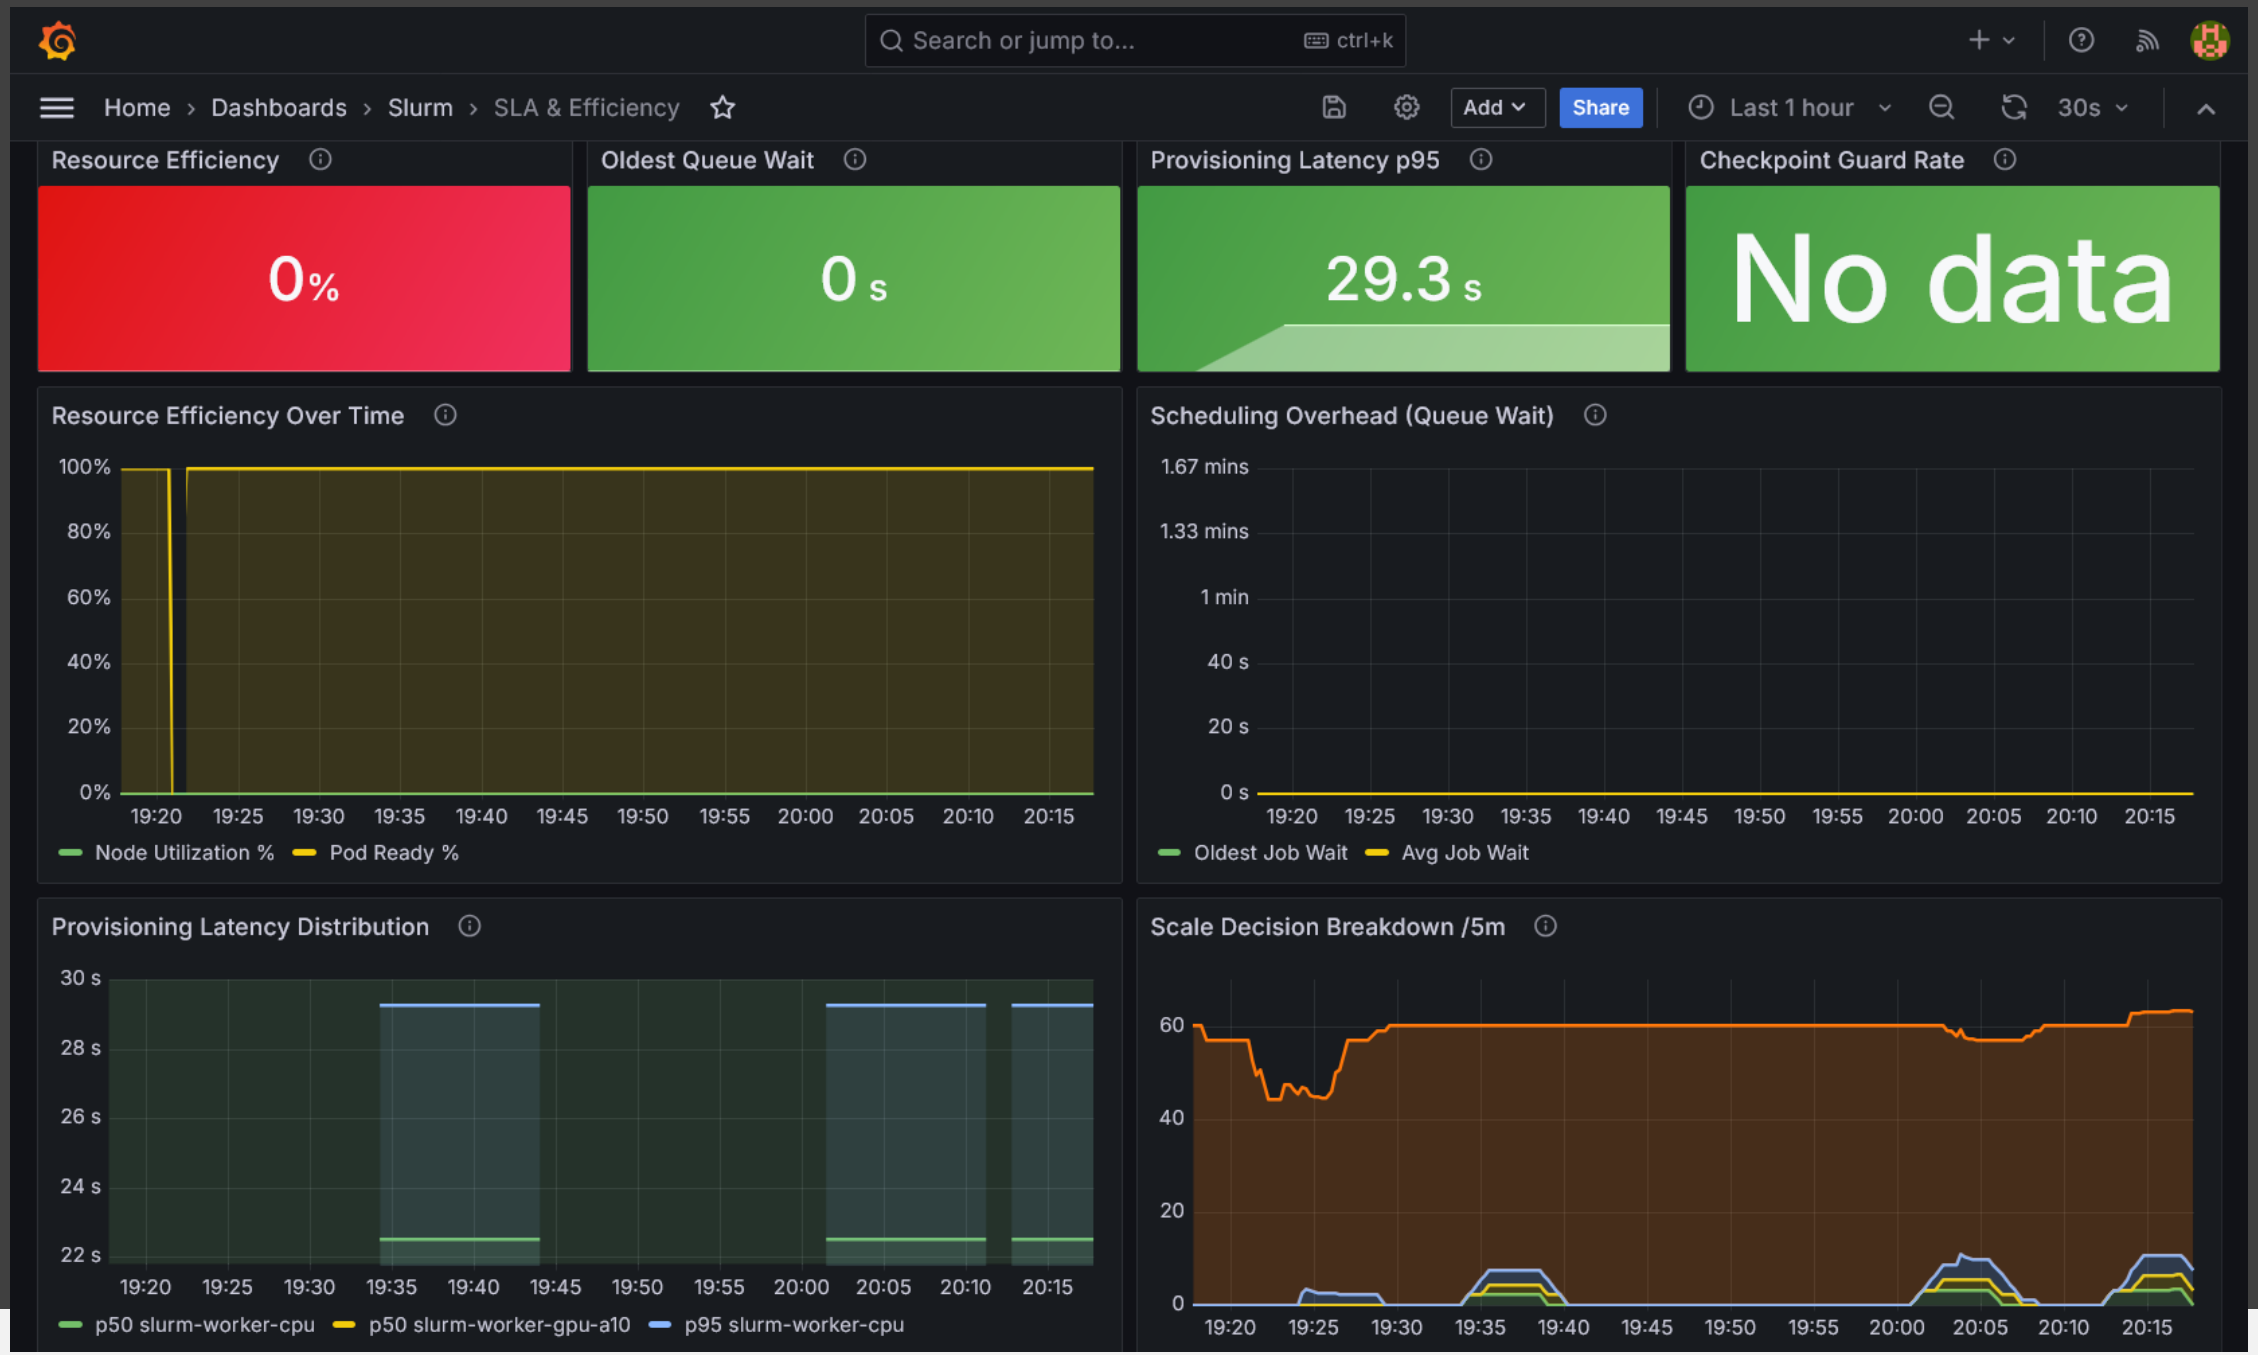
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › SLA & Efficiency
Add
Share
Last 1 hour
30s
Resource Efficiency
0%
Oldest Queue Wait
0 s
Provisioning Latency p95
29.3 s
Checkpoint Guard Rate
No data
Resource Efficiency Over Time
100%
80%
60%
40%
20%
0%
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
Node Utilization %
Pod Ready %
Scheduling Overhead (Queue Wait)
1.67 mins
1.33 mins
1 min
40 s
20 s
0 s
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
Oldest Job Wait
Avg Job Wait
Provisioning Latency Distribution
30 s
28 s
26 s
24 s
22 s
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
p50 slurm-worker-cpu
p50 slurm-worker-gpu-a10
p95 slurm-worker-cpu
Scale Decision Breakdown /5m
60
40
20
0
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15

Networking

Network Flow

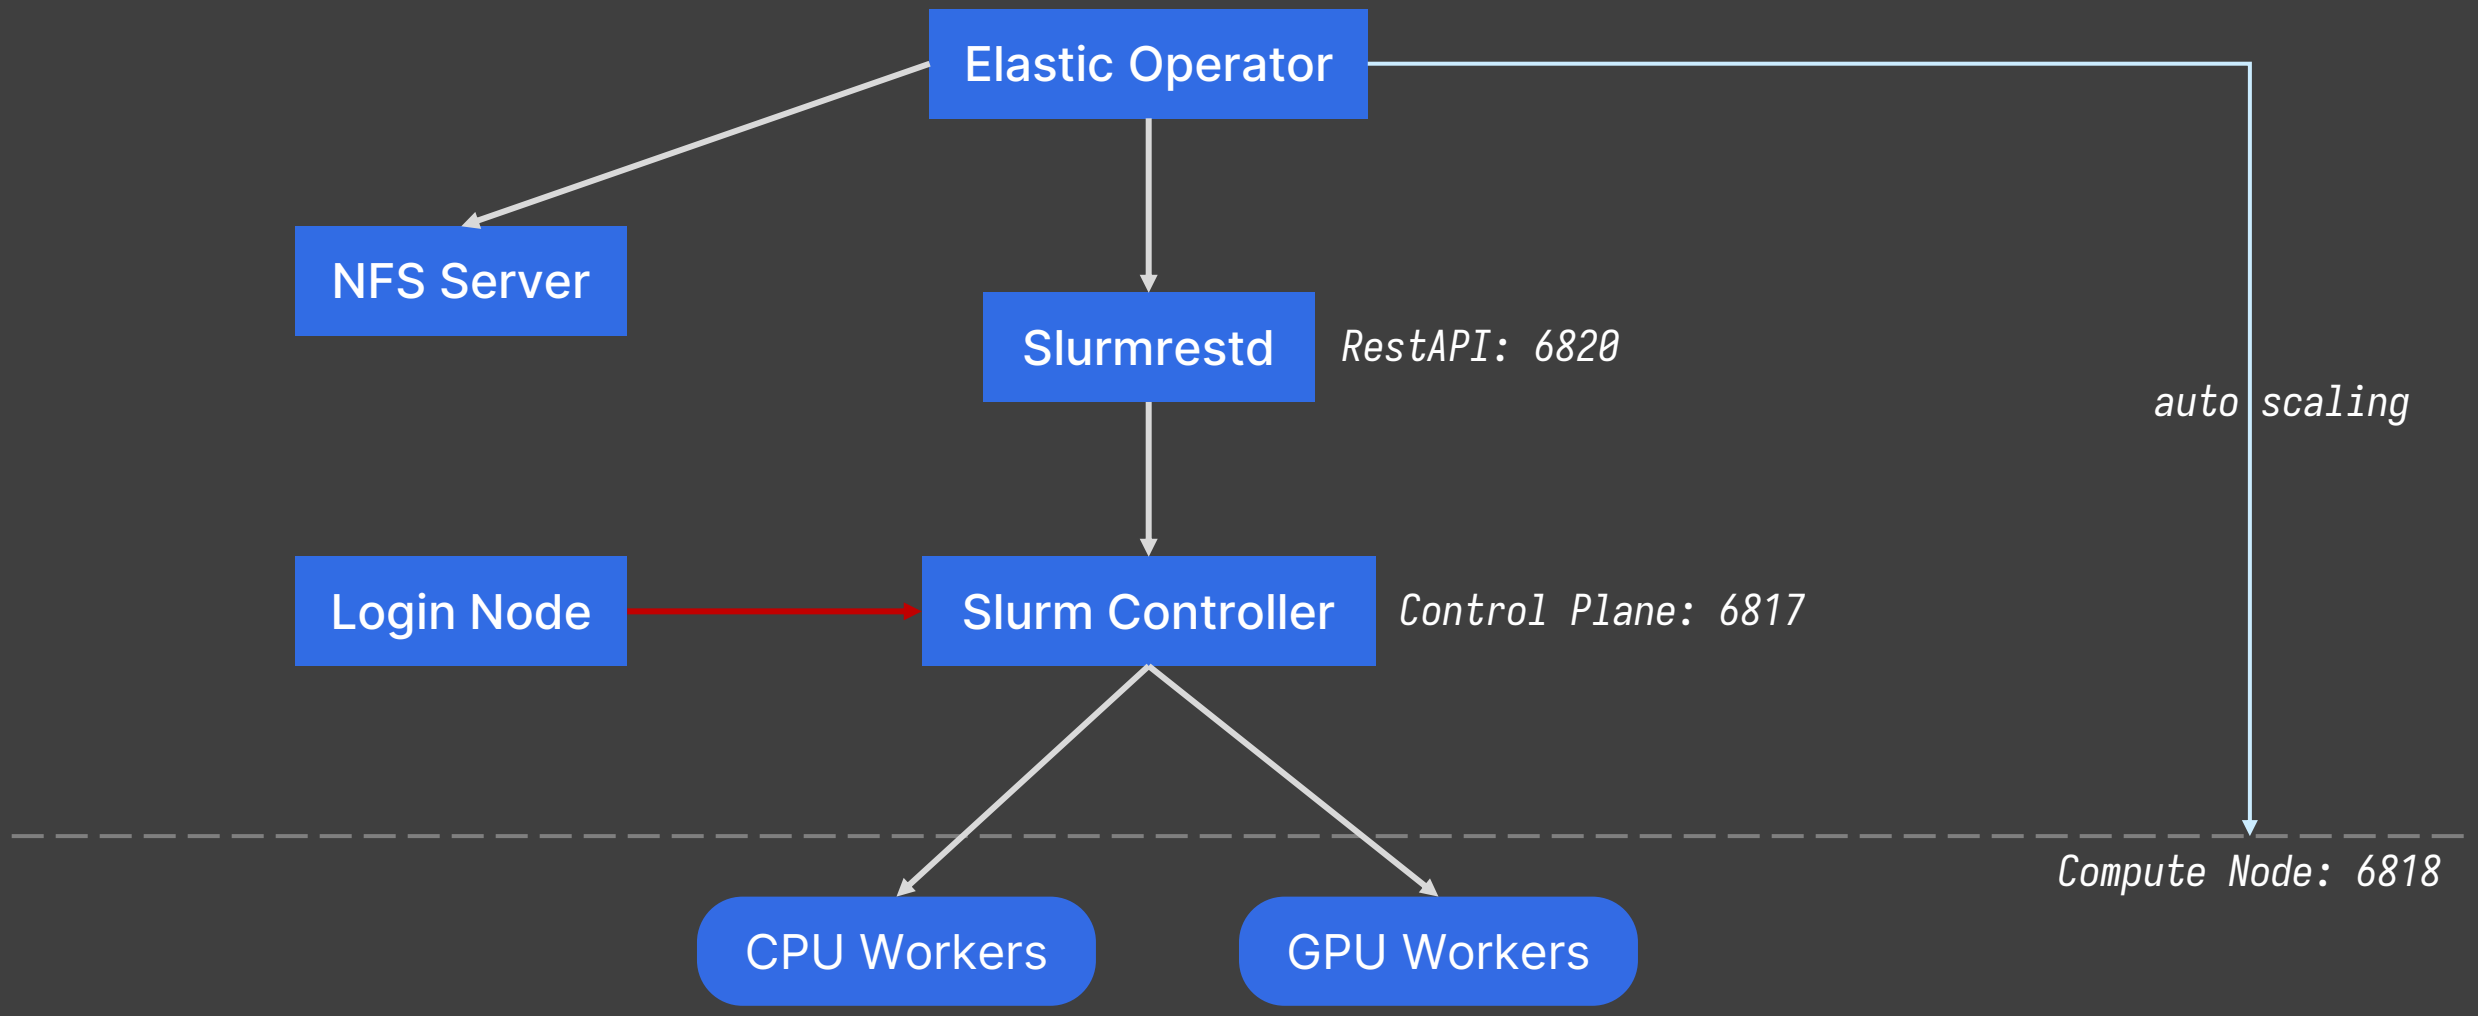

https://github.com/SoWiEee/Slurm-on-K8s-For-DDP/blob/main/docs/cluster.md

Future Work

Helm Chart

- 切分容器/服務，部署需要依序執行多支 bootstrap 腳本。Helm 讓整個系統可以一條指令完成：

```
helm install slurm-on-k8s ./chart \
  --set cluster.name=my-lab \
  --set pools.cpu.maxReplicas=8 \
  --set pools.gpuA10.maxReplicas=4 \
  --set monitoring.enabled=true \
  --set alertmanager.slack.webhookUrl="https://hooks.slack.com/..."
```

- 主要收益：dev/prod 只需一份 yaml，消除目前「改完 JSON 還要重新 render manifest」的步驟。

https://helm.sh/docs/topics/charts/

Distributed Tracing (1/2)

- 搜集應用程式內部與端到端請求相關的資料，以實現對整個系統的監控和分析。

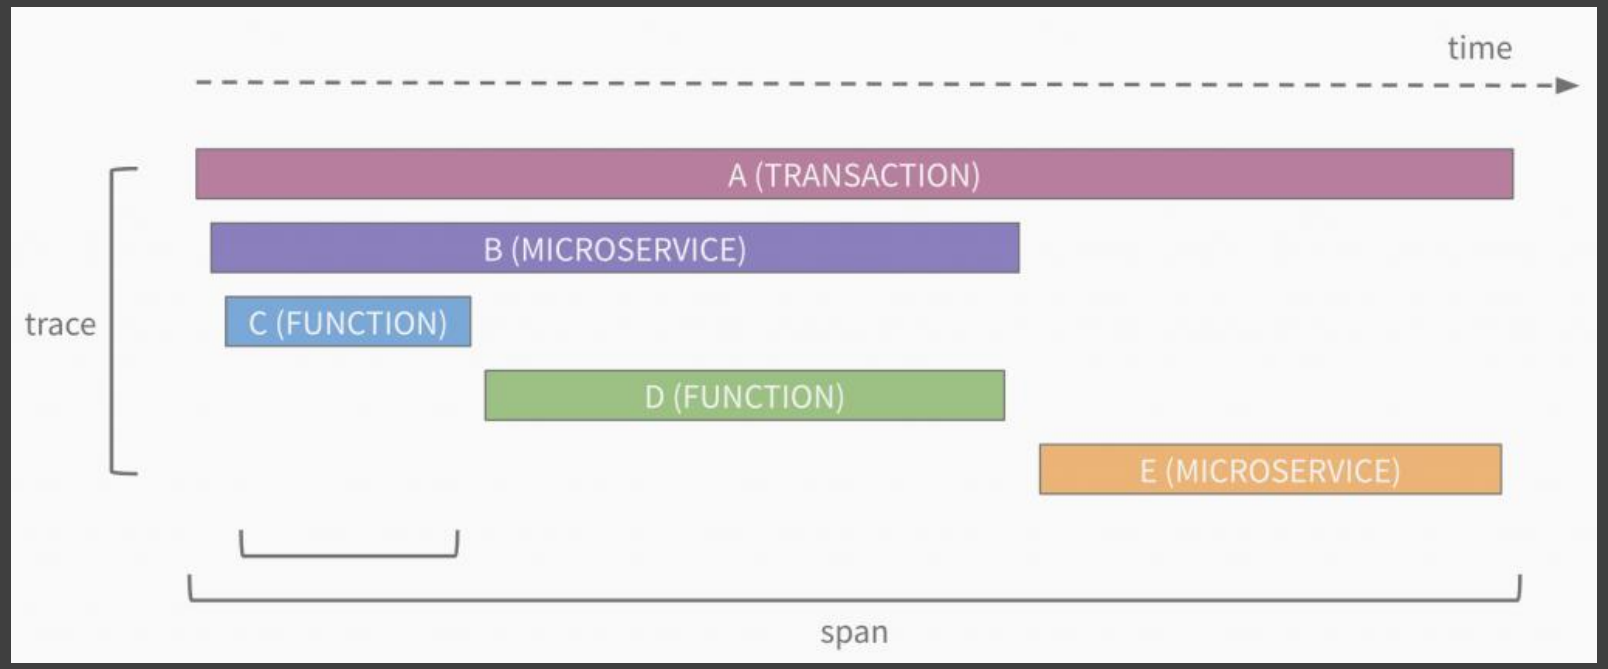

Distributed Tracing (2/2)

- 讓一個訓練 job 的完整生命週期變成一條可視化的 Trace：

```
[sbatch submit] → [pending in queue] → [scale-up decision]
  → [K8s provisioning] → [slurmd registration] → [DDP torchrun]
    → [checkpoint write] → [scale-down decision] → [job complete]
```

- 紀錄 job_id, pool, checkpoint_age 等屬性

(+) Tools：Jaeger / Grafana Tempo

https://grafana.com/oss/tempo/

Security

The 4C's of Cloud Native Security

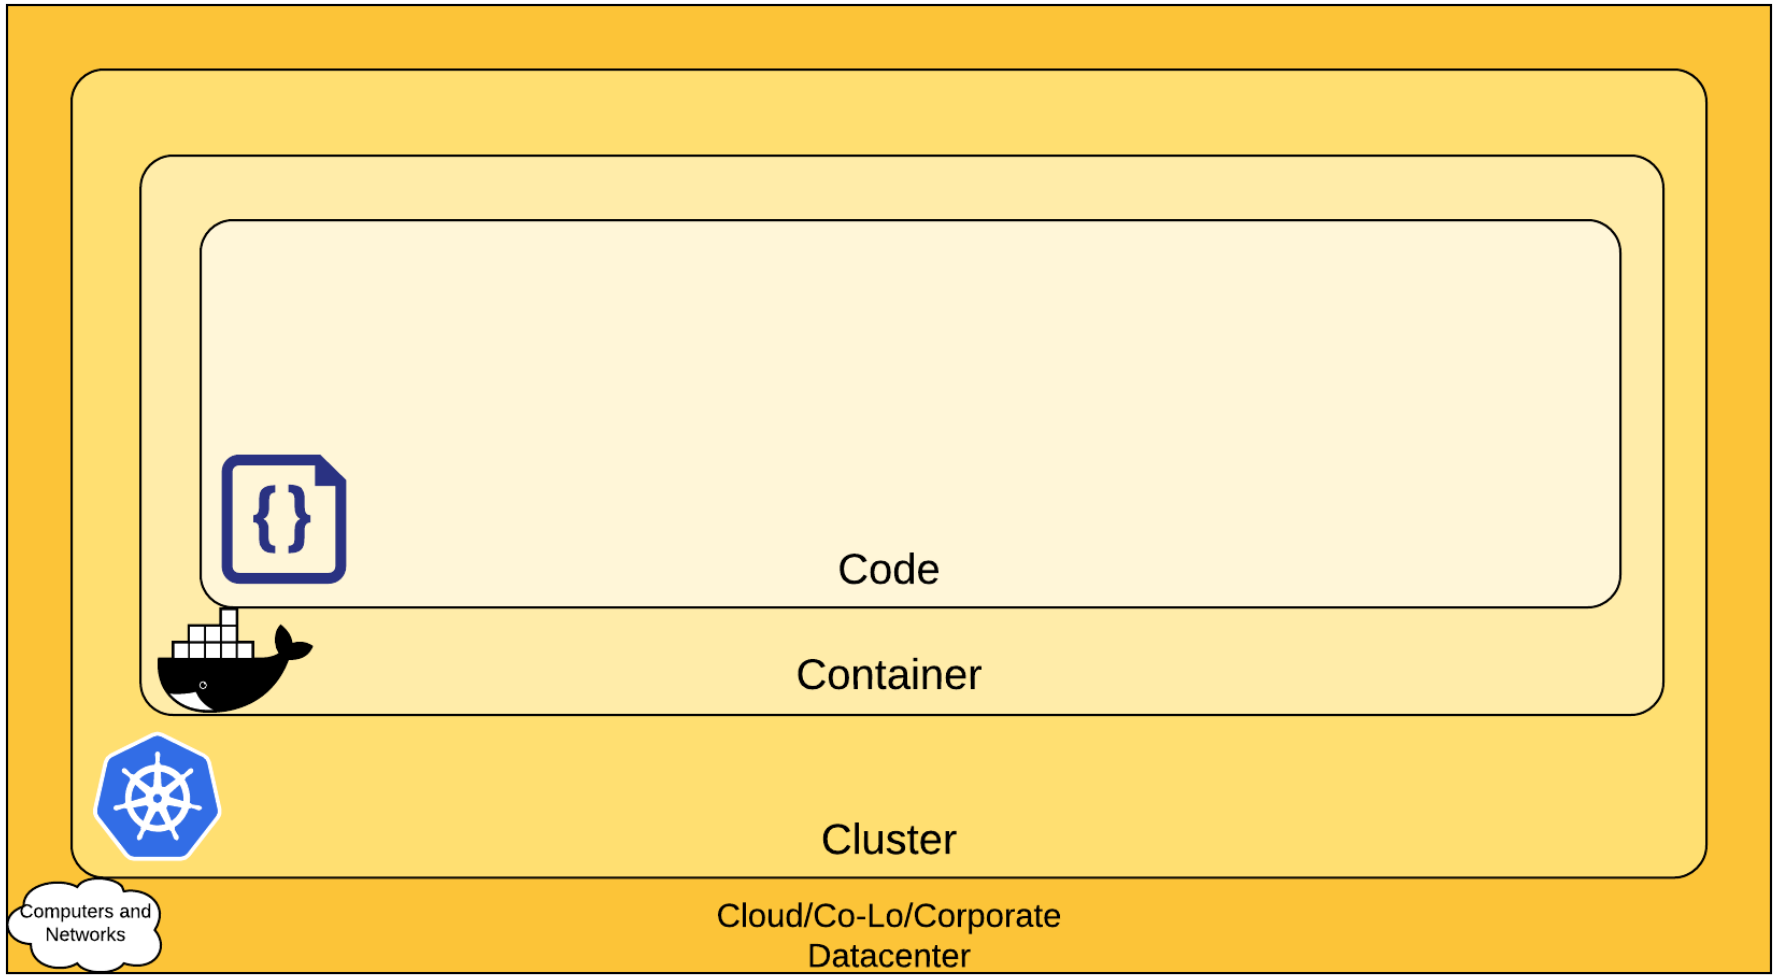

https://www.tigera.io/learn/guides/cloud-native-security/

Code Security

- 雖然應用程式原始碼的安全通常超出了 K8s 基礎設施的討論範圍，但它依然是整個雲端原生安全不可或缺的一環。
- 實施靜態/動態應用程式安全測試 (SAST / DAST)
- 定期掃描與更新第三方程式庫與相依套件
- 防範常見的應用程式漏洞 (OWASP Top 10)

Container Security

- 運行環境的權限設定，最小權限原則
- 容器內部軟體是否本身就有安全性漏洞
- Image 本身的數位簽章

Cluster Security

- 主要針對 K8s 叢集本身的防護
- 必須根據應用程式的攻擊面來配置安全策略：
  - RBAC/Auth
  - Secrets Management
  - Pod 安全規範
  - QoS & Resource limit
  - Network Policies
  - TLS 加密

Cloud Security

- 這是整個安全模型的地基，也是 Kubernetes 叢集的信任基礎
- 如果雲端層本身存在漏洞，或者設定不當，那麼建構在其上的所有元件都無法保證安全。
- 嚴格遵守各家雲端服務供應商（AWS, GCP, Azure）針對其環境所提出的基礎設施安全建議與最佳實踐。