CLOUD NATIVE
COMPUTING FOUNDATION

Slurm-on-K8s For DDP

Adaptive HPC Scheduling on
Cloud Native Infrastructure
For Distributed Training

2025.04.30

Agenda

1. Introduction
2. System Architecture
3. Demo & Evaluation
4. References

01. Introduction

專題簡介

Example Scenarios

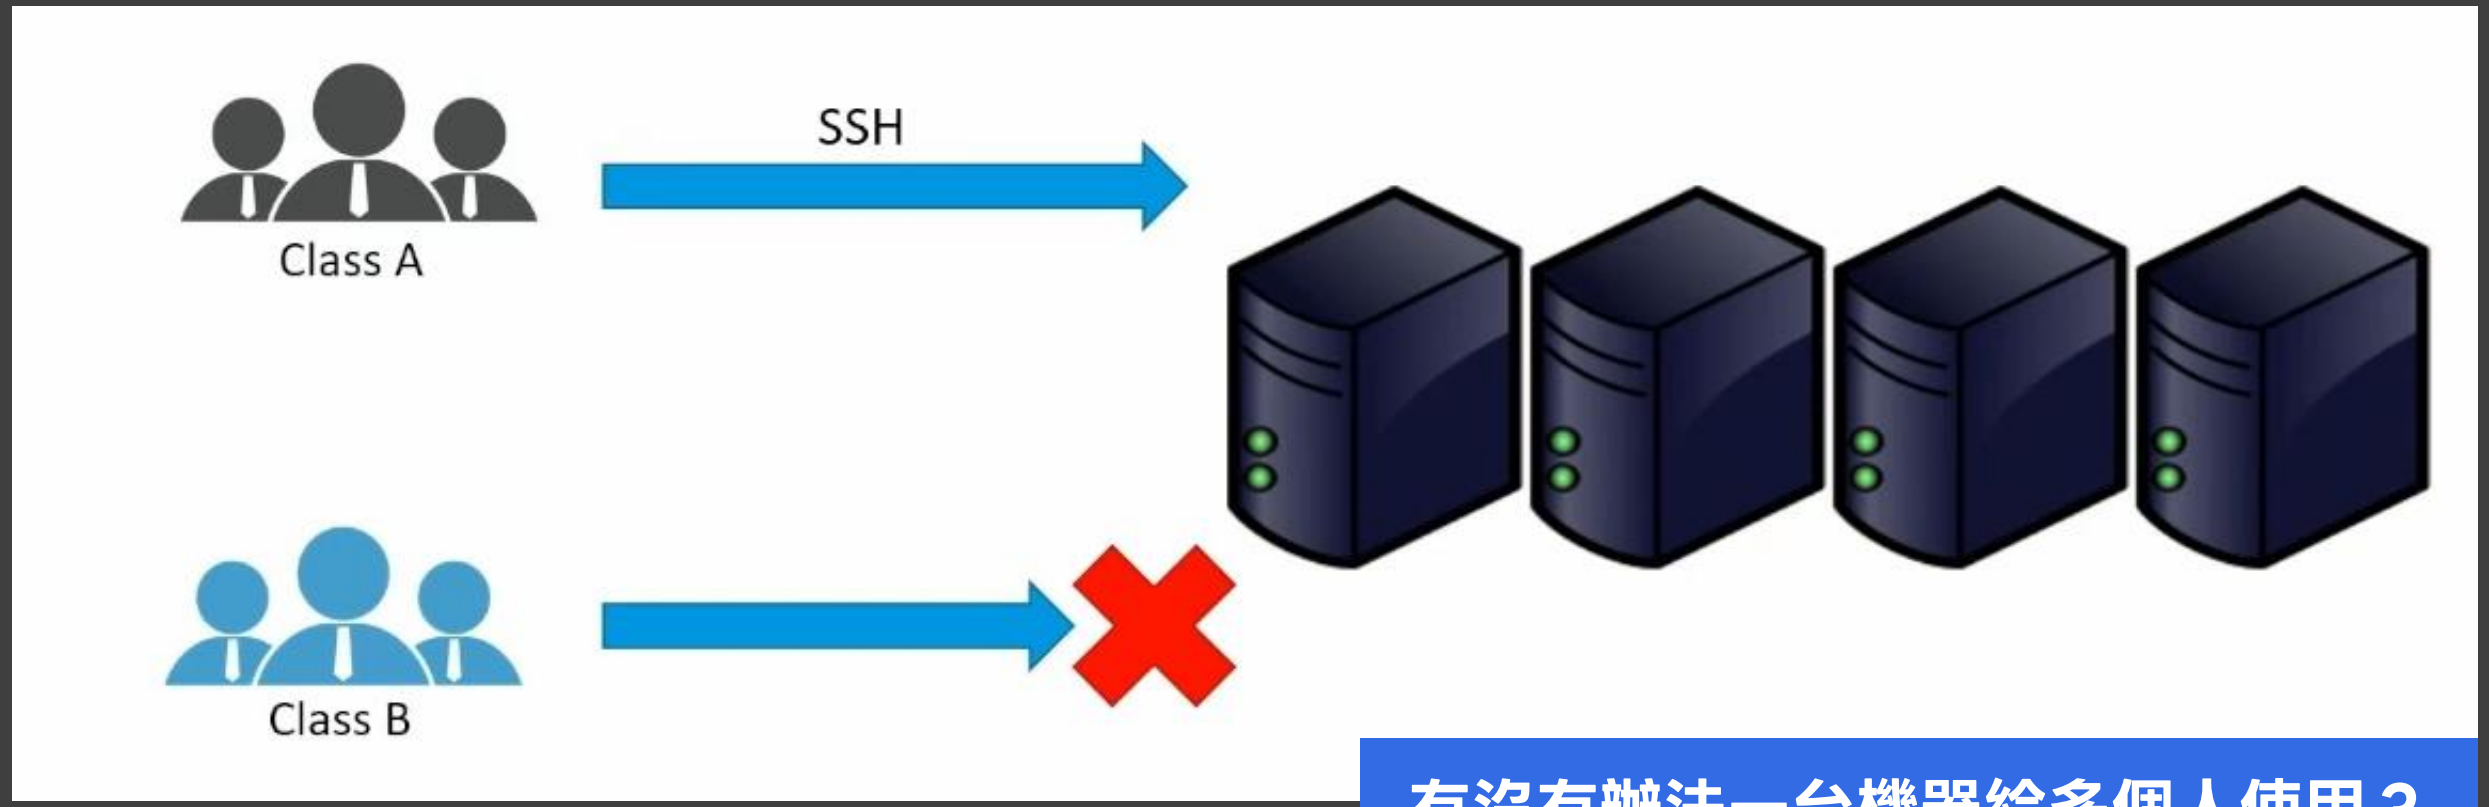

有沒有辦法一台機器給多個人使用？

Example Scenarios

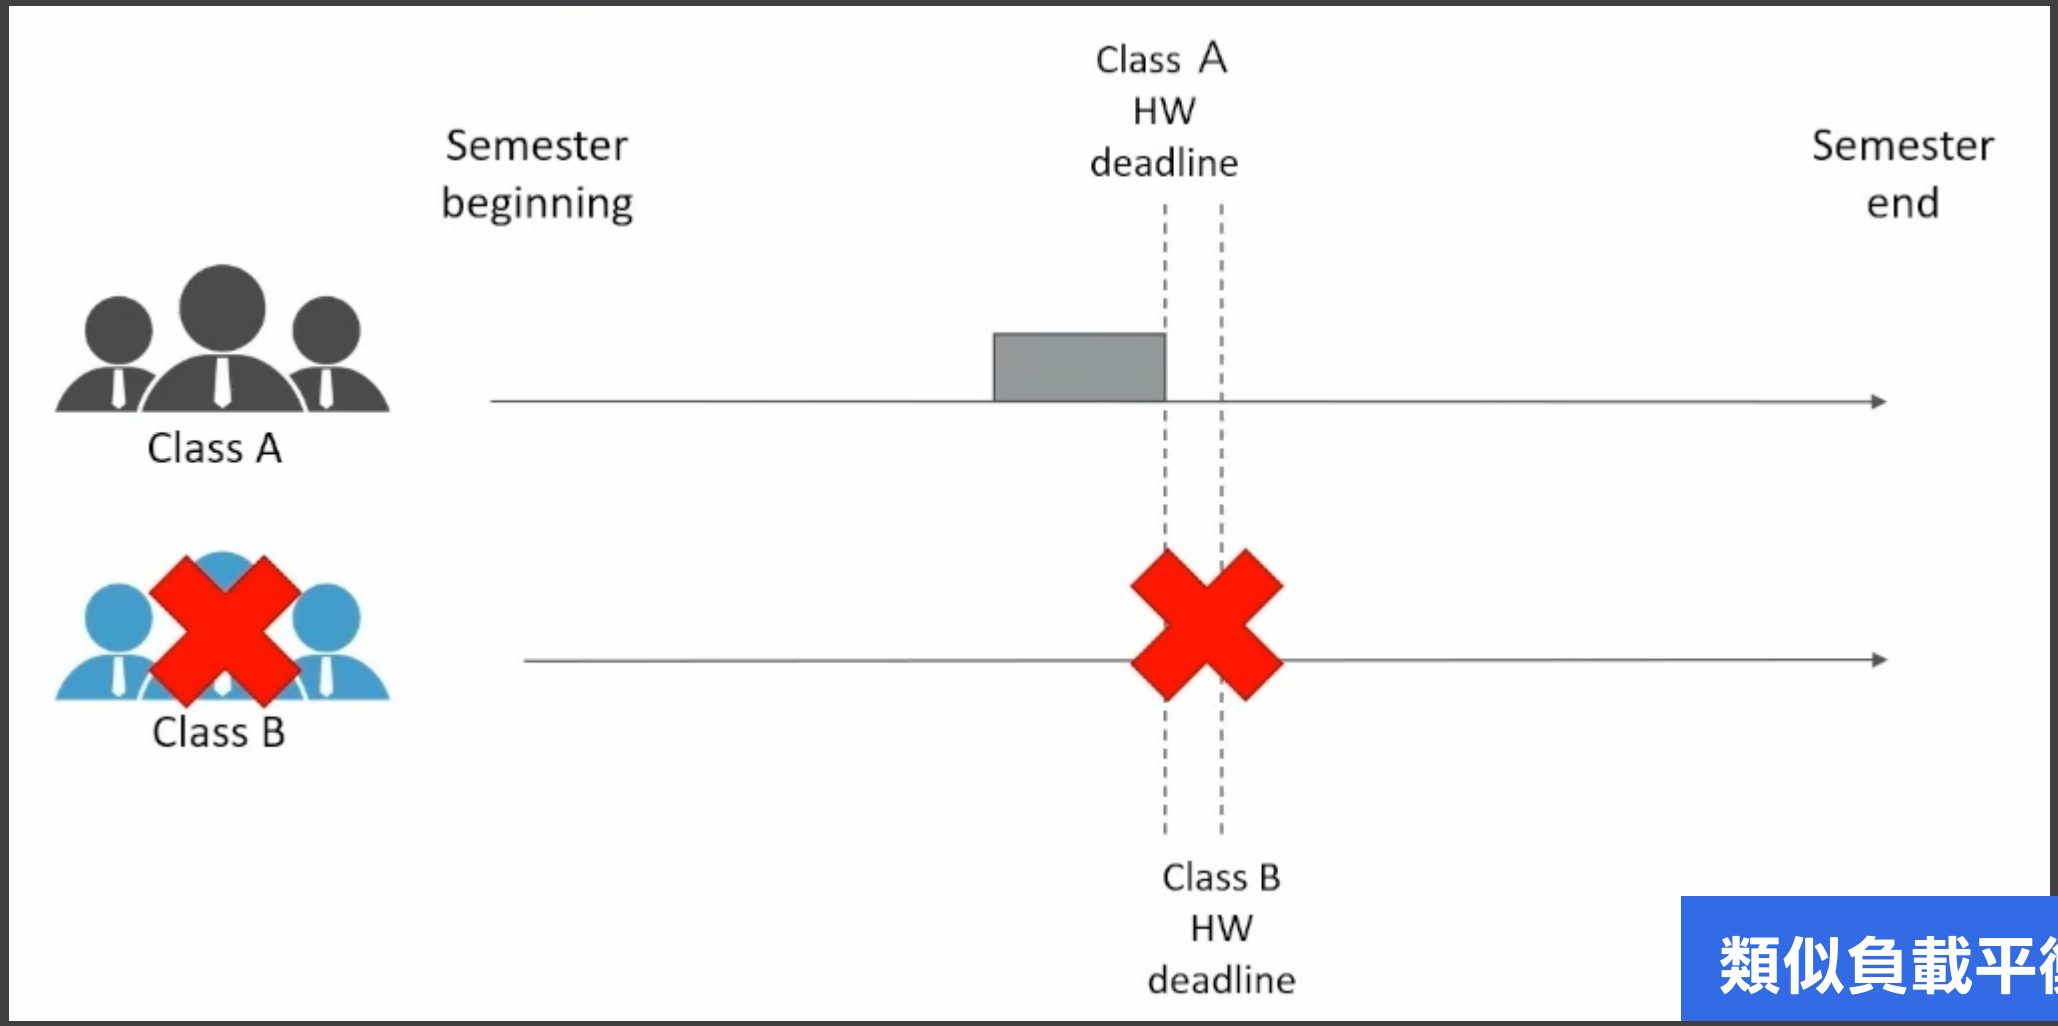

類似負載平衡的概念

Slurm

What is Slurm？

- Slurm = Simple Linux Utility for Resource Management
- An open source system
  - 管理工作：資料分配、排程、執行

Roles in Slurm

- Login nodes = 接待員/客服
- Controller = 主管
- Compute nodes = 工人
- DB interface = 會計師

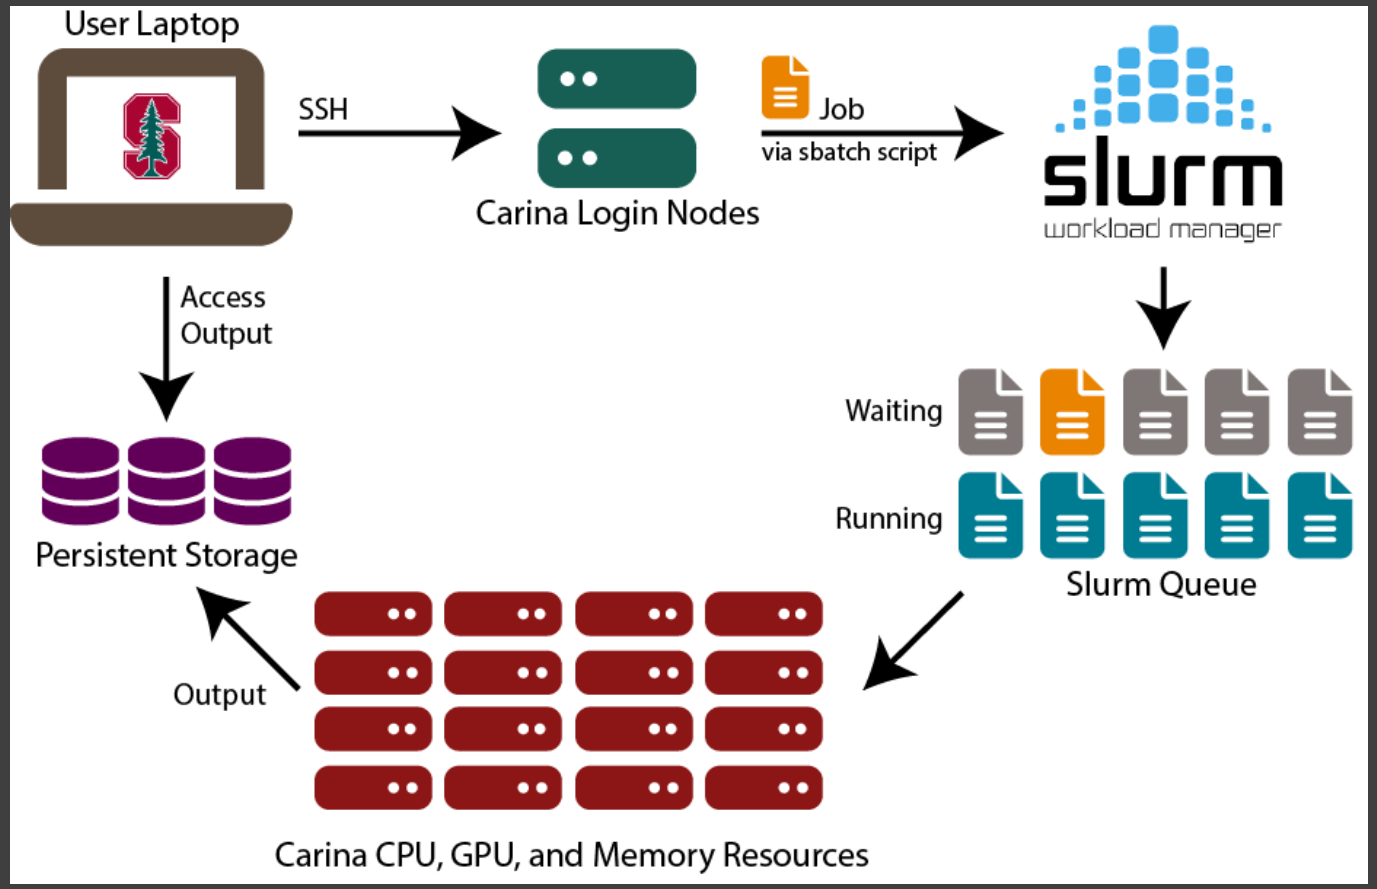

Running a job in Slurm (srun)

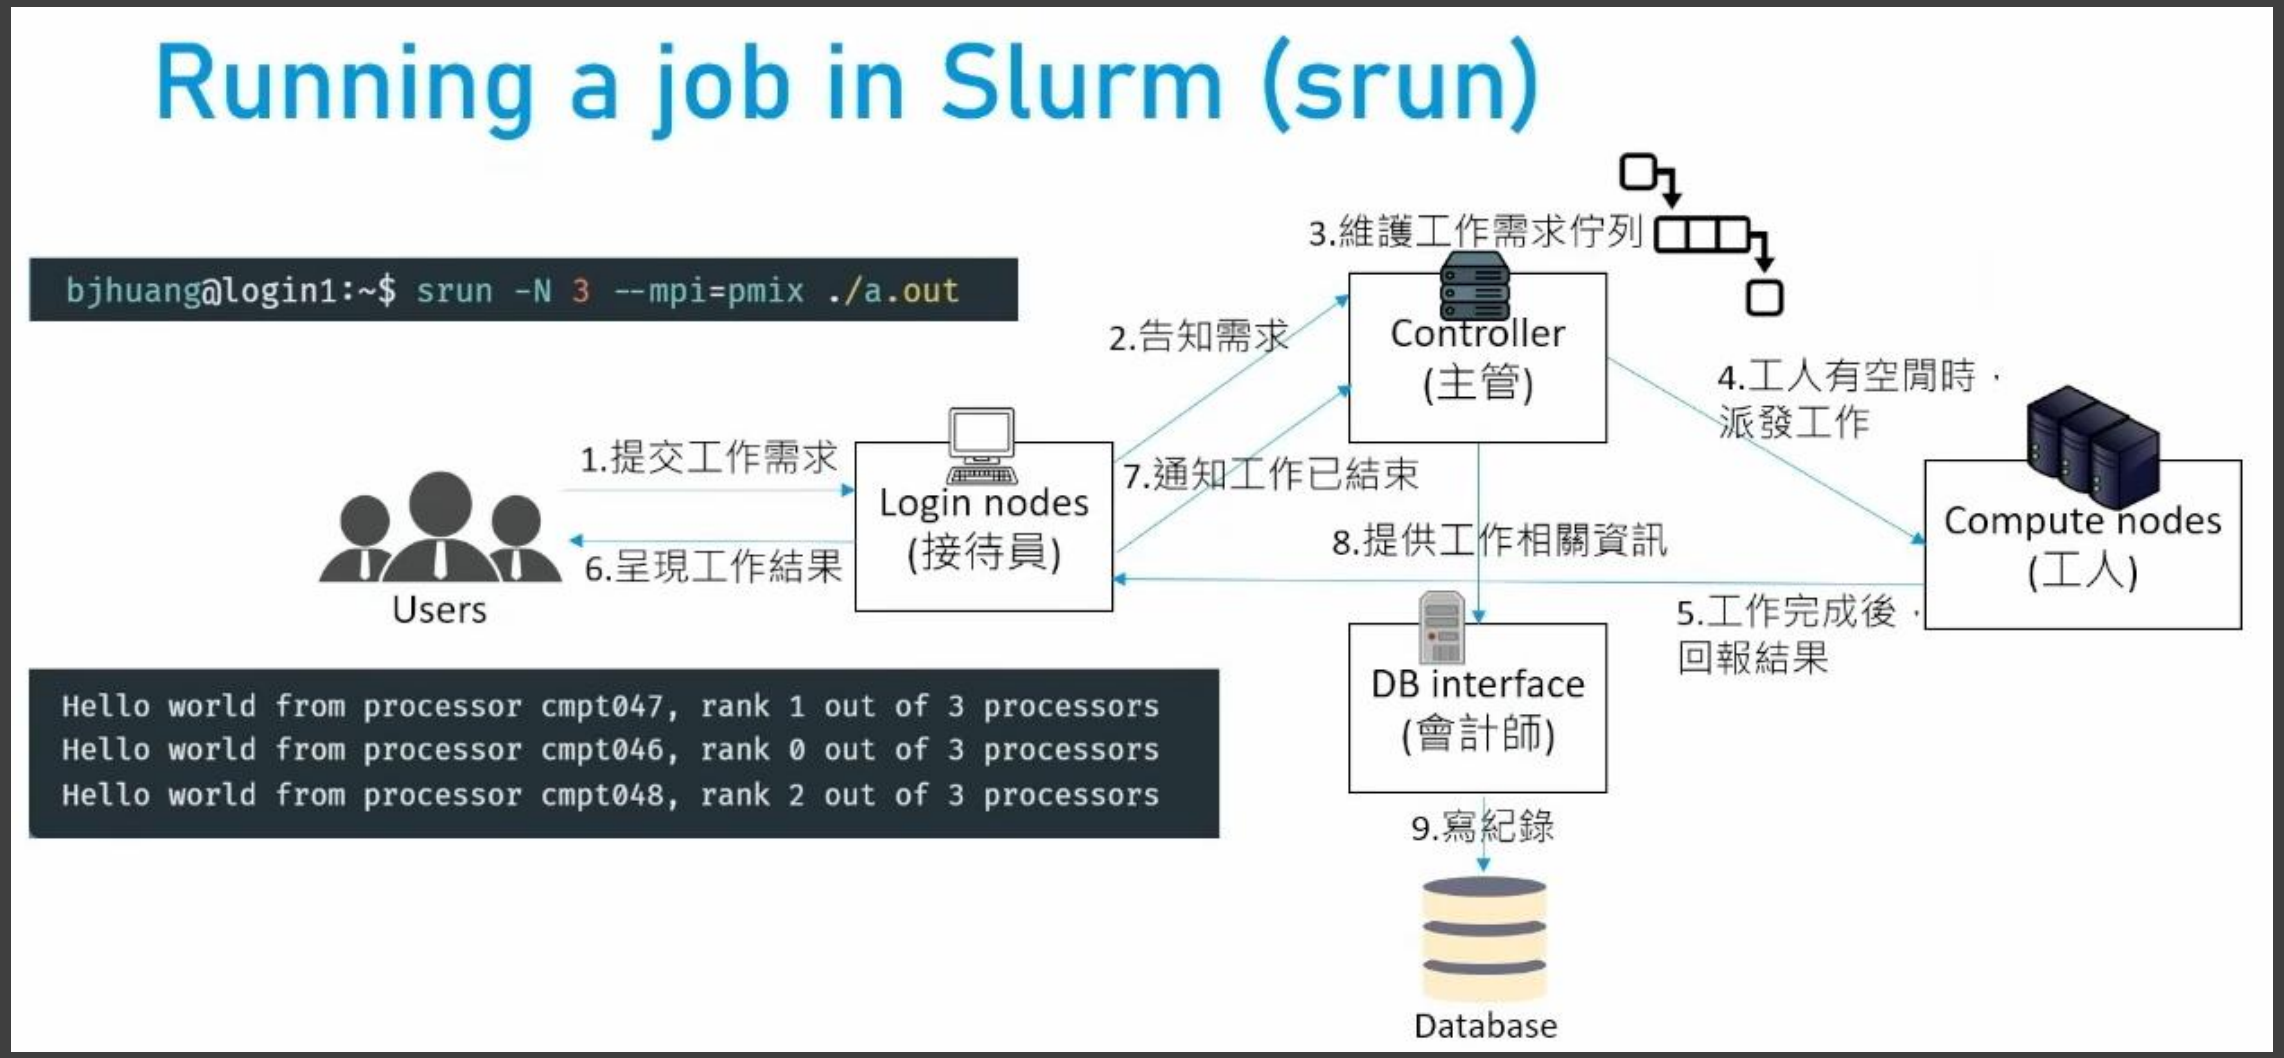

Kubernetes

What is Kubernetes？

- Kubernetes (K8s) = Containers Orchestration Tool
- An open source system
  - 管理容器：啟動、運算資源、排程、自動部署
  - 大公司架設服務很愛用

Kubernetes Distribution

- 本來是用 kind，但硬體支援度有極限，改成使用 K3s
- 建立在 Kubernetes 標準安裝之上的一個輕量發行版
- 由 Rancher Labs 開發，通過 CNCF 認證。

K3s

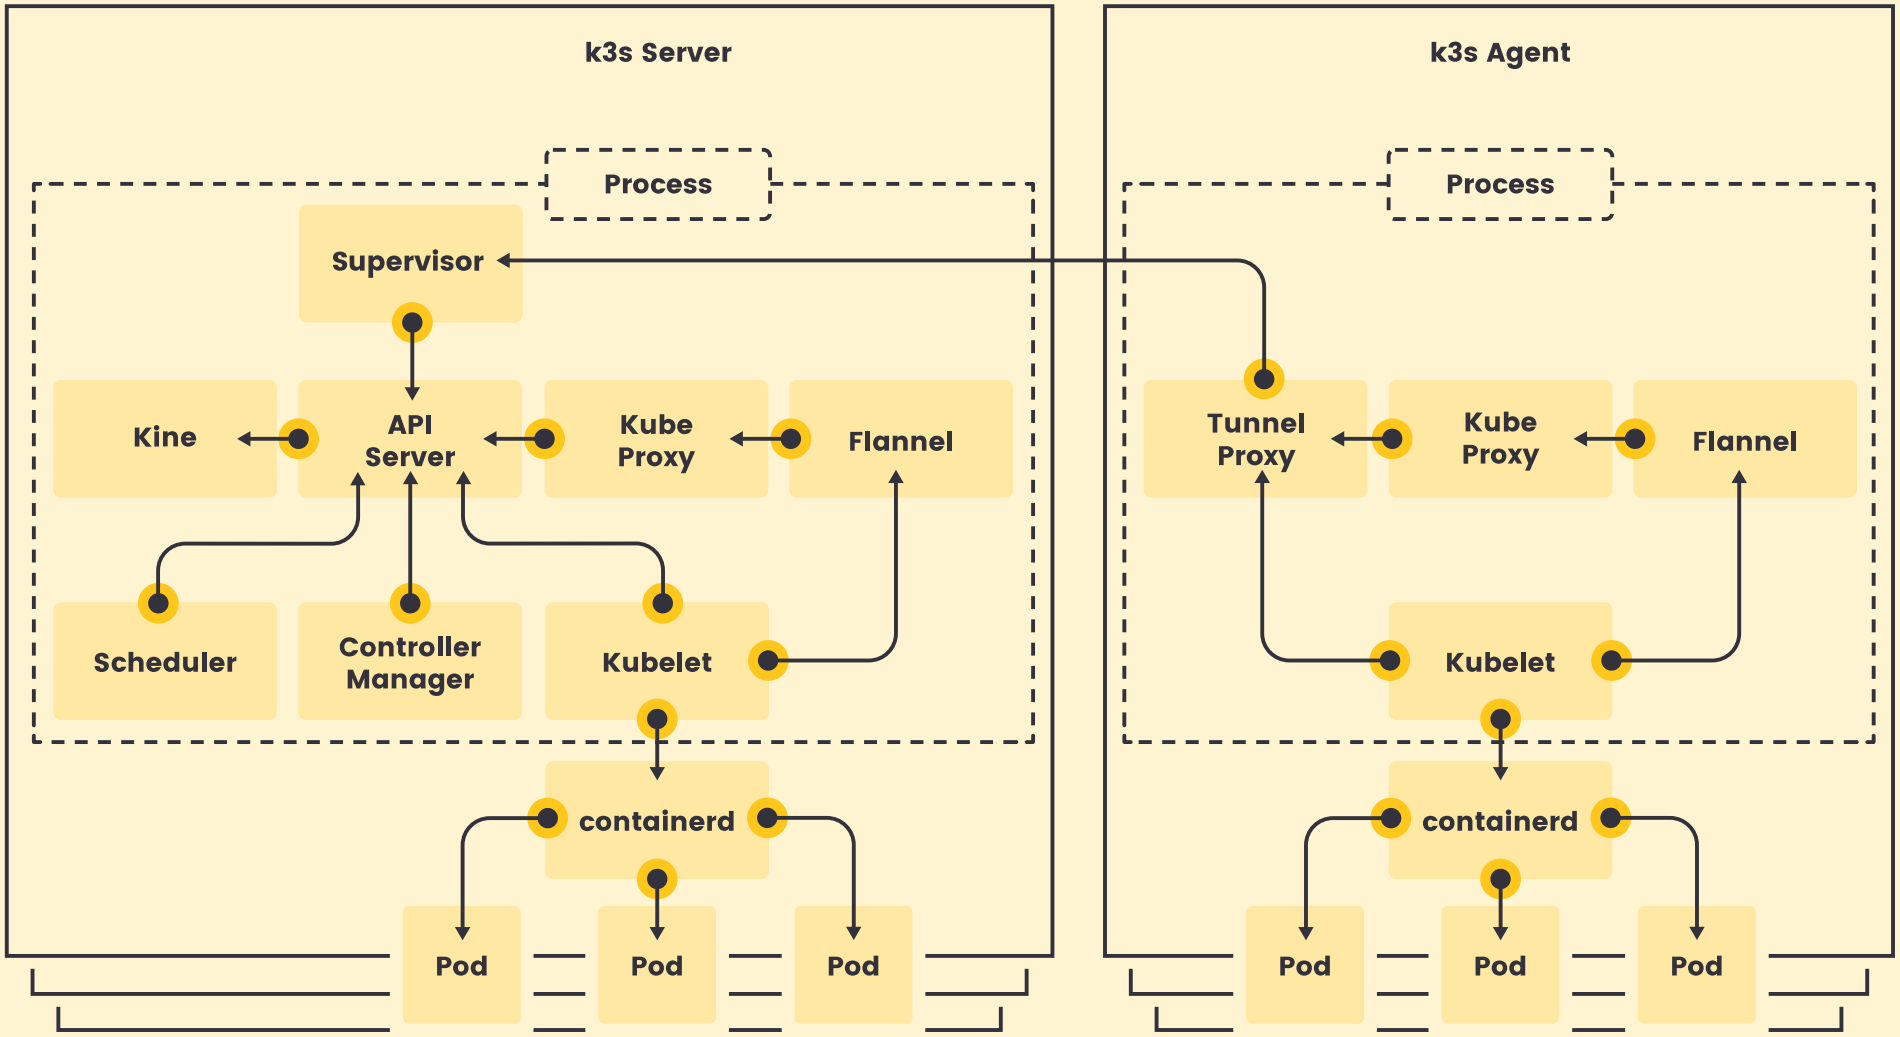
k3s Server
Process
Supervisor
Kine
API Server
Kube Proxy
Flannel
Scheduler
Controller Manager
Kubelet
containerd
Pod
Pod
Pod
k3s Agent
Process
Tunnel Proxy
Kube Proxy
Flannel
Kubelet
containerd
Pod
Pod
Pod

Background

Motivation

- Kubernetes 很擅長資源編排與彈性伸縮，但對 HPC / AI 訓練工作負載的語意支援有限。
- Slurm 很擅長批次排程、資源配額與叢集治理，但傳統部署通常偏靜態，對雲端環境的節點生命週期不夠友善。

⟹ 結合兩者來做 AI/ML _____

Benefits

- 提升資源利用率
  - Slurm 可以透過將工作排程到 K8s 叢集中的可用資源
- 簡化的工作負載管理
  - 一律透過 Slurm 介面，用於管理 ML 工作負載
- 提升可擴展性
  - Slurm 可以透過將機器學習工作負載排程到多個 K8s 叢集來擴展

Present Solutions

- Slurm-on-Kubernetes：CoreWeave’s SUNK
- Slinky 專案
  - slurm-operator：用 K8s CRD 管理 Slurm 的 controller / login / nodeset（把 Pod 當成 Slurm node）。
  - slurm-bridge：讓 Slurm 可以把 workload 映射到 K8s Pod。

Slurm on Kubernetes

- Slurm 決定誰用資源、什麼時候用、用多少
  - 計算資源排程問題
- Kubernetes 決定資源怎麼存在、怎麼啟動、怎麼管理
  - 動態提供 Slurm 需要的運算節點
  - 當硬體調整的時候不用重新調整 Slurm 設定
  - 依賴版本管理、網路設定

Our Feature !

- 擴容、擴縮、低功耗、節點壞掉重啟
- 客製化排程演算法、運算資源分配
- 針對分散式訓練 (DDP)
- 近年來企業很重視安全，可以裝個龍蝦
- Checkpoint Guard

Reliability

Performance

Lifecycle Unity

Observability

Target Audience (TA)

- 學術單位、企業 AI 平台，多個研究小組共用 GPU 叢集
- AI 研究平台工程師（學術單位、企業 MLOps）
  - 一鍵部署、多租戶隔離、SLO 告警整合到既有 on-call 流程。
- 雲端架構師 / SRE：需要 HA、可觀測性、Terraform / ArgoCD 整合的 IaC 交付形式。

02. System Architecture

系統設計與架構

Development Environment

- Docker Desktop + K3s/RKE2
- Kind cluster (slurm-lab)　單節點本機叢集，模擬多 Pod 場景
- Controller&Worker：Ubuntu 22.04 + Slurm + Munge + OpenSSH
- Operator：Python 3.11-slim + kubectl CLI

https://kind.sigs.k8s.io/

Slurm GRES (1/3)

- Slurm 的通用資源管理機制，讓 Slurm 能夠追蹤和排程 CPU/Memory 以外的資源 (e.g. GPU)
- 知道每個 node 上有哪些 GPU（型號、數量）
- 讓使用者提交 job 時指定需要的 GPU 類型和數量
- 確保 GPU 資源不會被過度分配

Slurm GRES (2/3)

- Slurm 可以自動偵測，但在 Kind 模擬要手動設定 vGPU

GPU Resources

Multi-Process Service (MPS)

- 在 GPU 上創建多個 context，將 GPU 的資源分配給多個 process
- 每個進程擁有一個獨立的 context，可以獨立執行其計算任務，仿佛擁有獨立的 GPU。
- Linux-specific
- 可以提升推論速度

https://docs.nvidia.com/deploy/mps/index.html | https://ithelp.ithome.com.tw/m/articles/10366226

Observability

Observability

雲端服務崛起

錯誤排查難度上升

Observability

Slurm	Bridge	K8s
Queue depth	Operator scale decision	StatefulSet replicas
Job wait-time	Scale-up event	Pod ready time
Node idle-time	Scale-down decision	Replica count drop
Checkpoint age	Guard blocked / allowed	Scale event skipped

Prometheus

- 最受歡迎的開源監控與告警工具組，是 CNCF 的畢業專案
- 專為動態雲端環境設計，擅長透過 HTTP 拉取模型收集指標，儲存於時間序列資料庫中，並使用 PromQL 進行數據查詢分析。
- 負責發 Alert 到 Slack/Telegram

https://wade-software-study-note.medium.com/devops%E8%AA%B2%E7%A8%8B-prometheus-1-7a690f7d4426

Grafana

- 能夠將各種資料做成監控儀表板，支援多種資料來源，以及提供豐富的面板選擇，協助我們將資料視覺化。
- Prometheus 預設的 GUI 功能不足，需要 Grafana 這種支援豐富圖表的工具幫助我們可視化 Metrics 資訊。

https://www.figma.com/deck/O8BwdzmRUfedbq0s8w7gm8/sitcon2026-grafana-v3?node-id=21-158

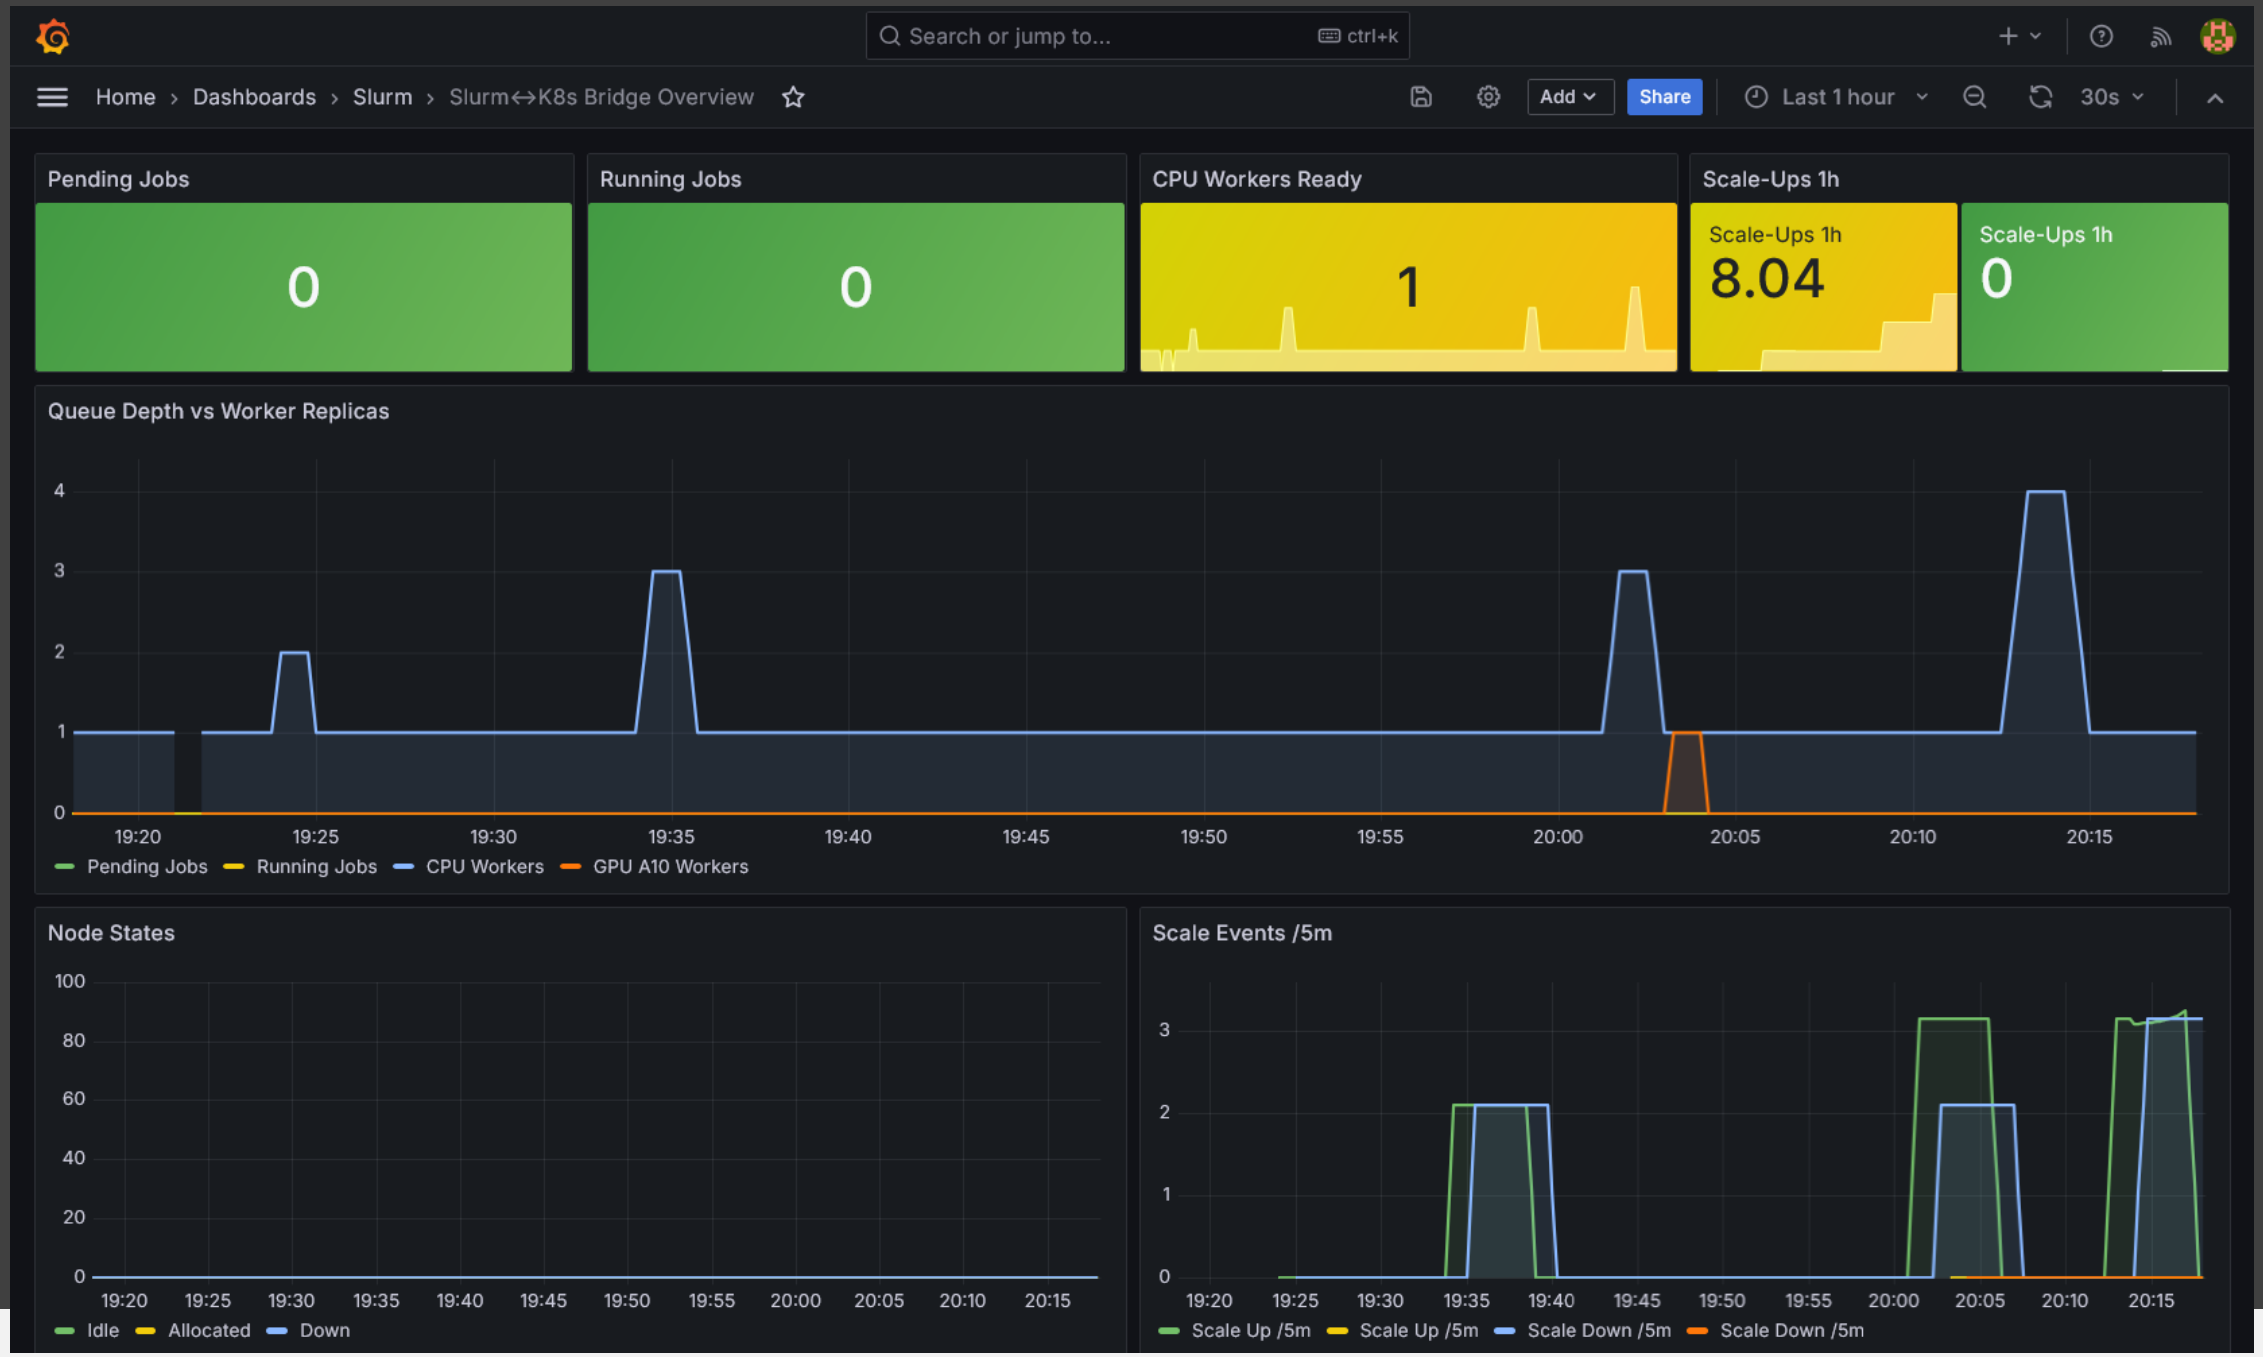
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › Slurm↔K8s Bridge Overview
Add
Share
Last 1 hour
30s
Pending Jobs
0
Running Jobs
0
CPU Workers Ready
1
Scale-Ups 1h
Scale-Ups 1h
8.04
Scale-Ups 1h
0
Queue Depth vs Worker Replicas
4
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Pending Jobs
Running Jobs
CPU Workers
GPU A10 Workers
Node States
100
80
60
40
20
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Idle
Allocated
Down
Scale Events /5m
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
Scale Up /5m
Scale Up /5m
Scale Down /5m
Scale Down /5m

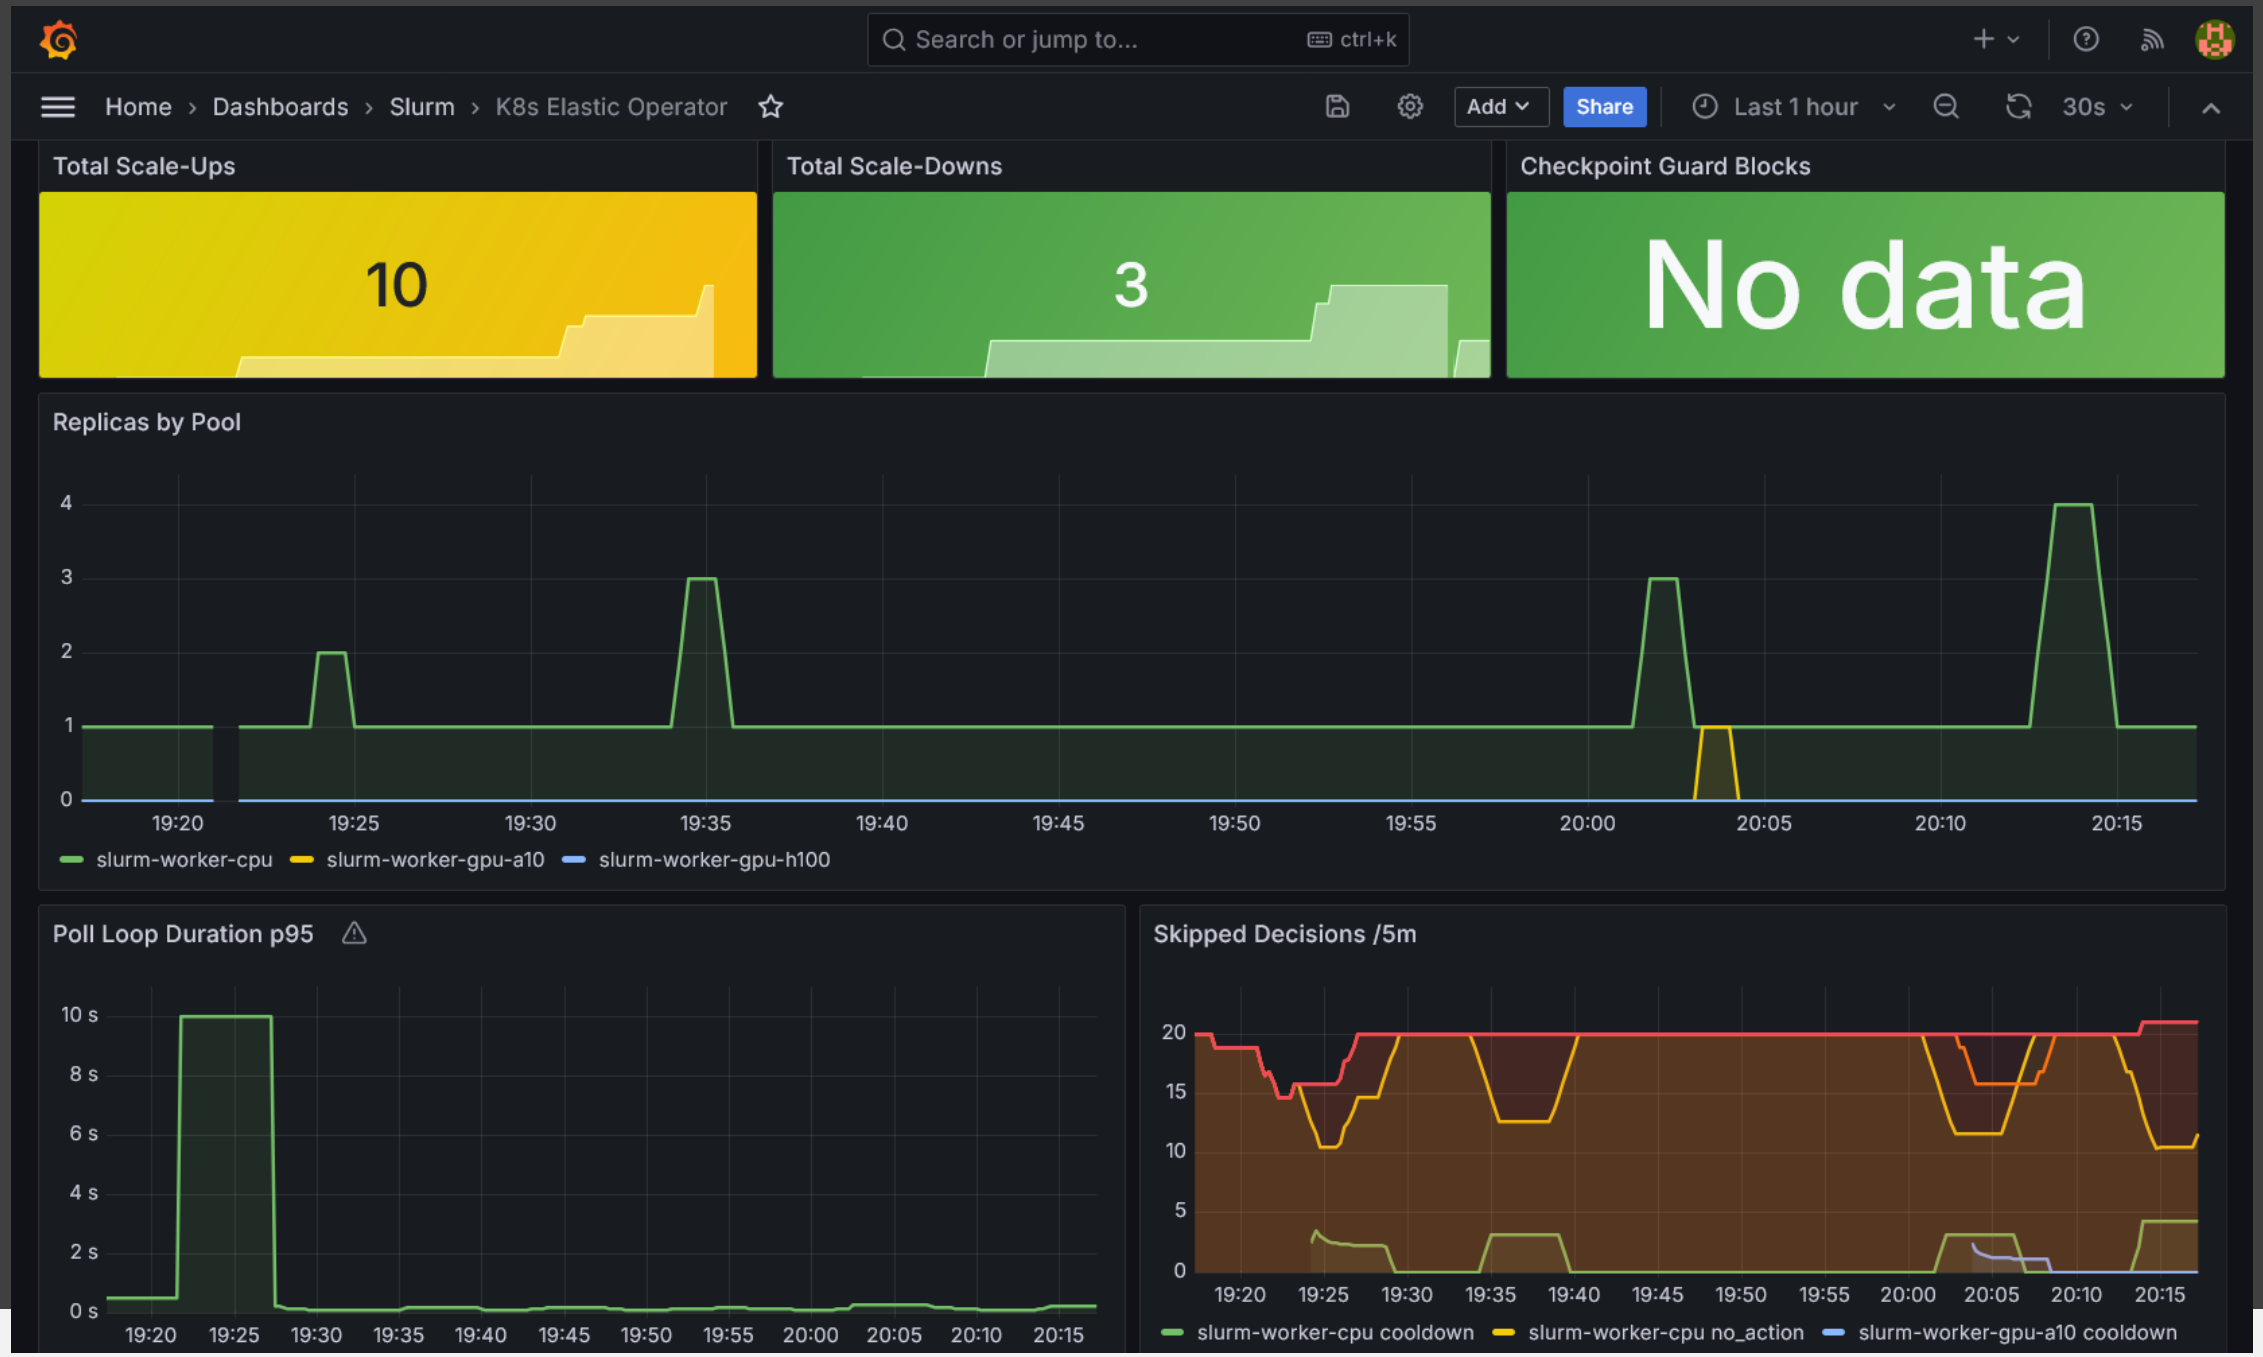
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › K8s Elastic Operator
Add
Share
Last 1 hour
30s
Total Scale-Ups
10
Total Scale-Downs
3
Checkpoint Guard Blocks
No data
Replicas by Pool
4
3
2
1
0
19:20
19:25
19:30
19:35
19:40
19:45
19:50
19:55
20:00
20:05
20:10
20:15
slurm-worker-cpu
slurm-worker-gpu-a10
slurm-worker-gpu-h100
Poll Loop Duration p95
10 s
8 s
6 s
4 s
2 s
0 s
Skipped Decisions /5m
20
15
10
5
0
slurm-worker-cpu cooldown
slurm-worker-cpu no_action
slurm-worker-gpu-a10 cooldown

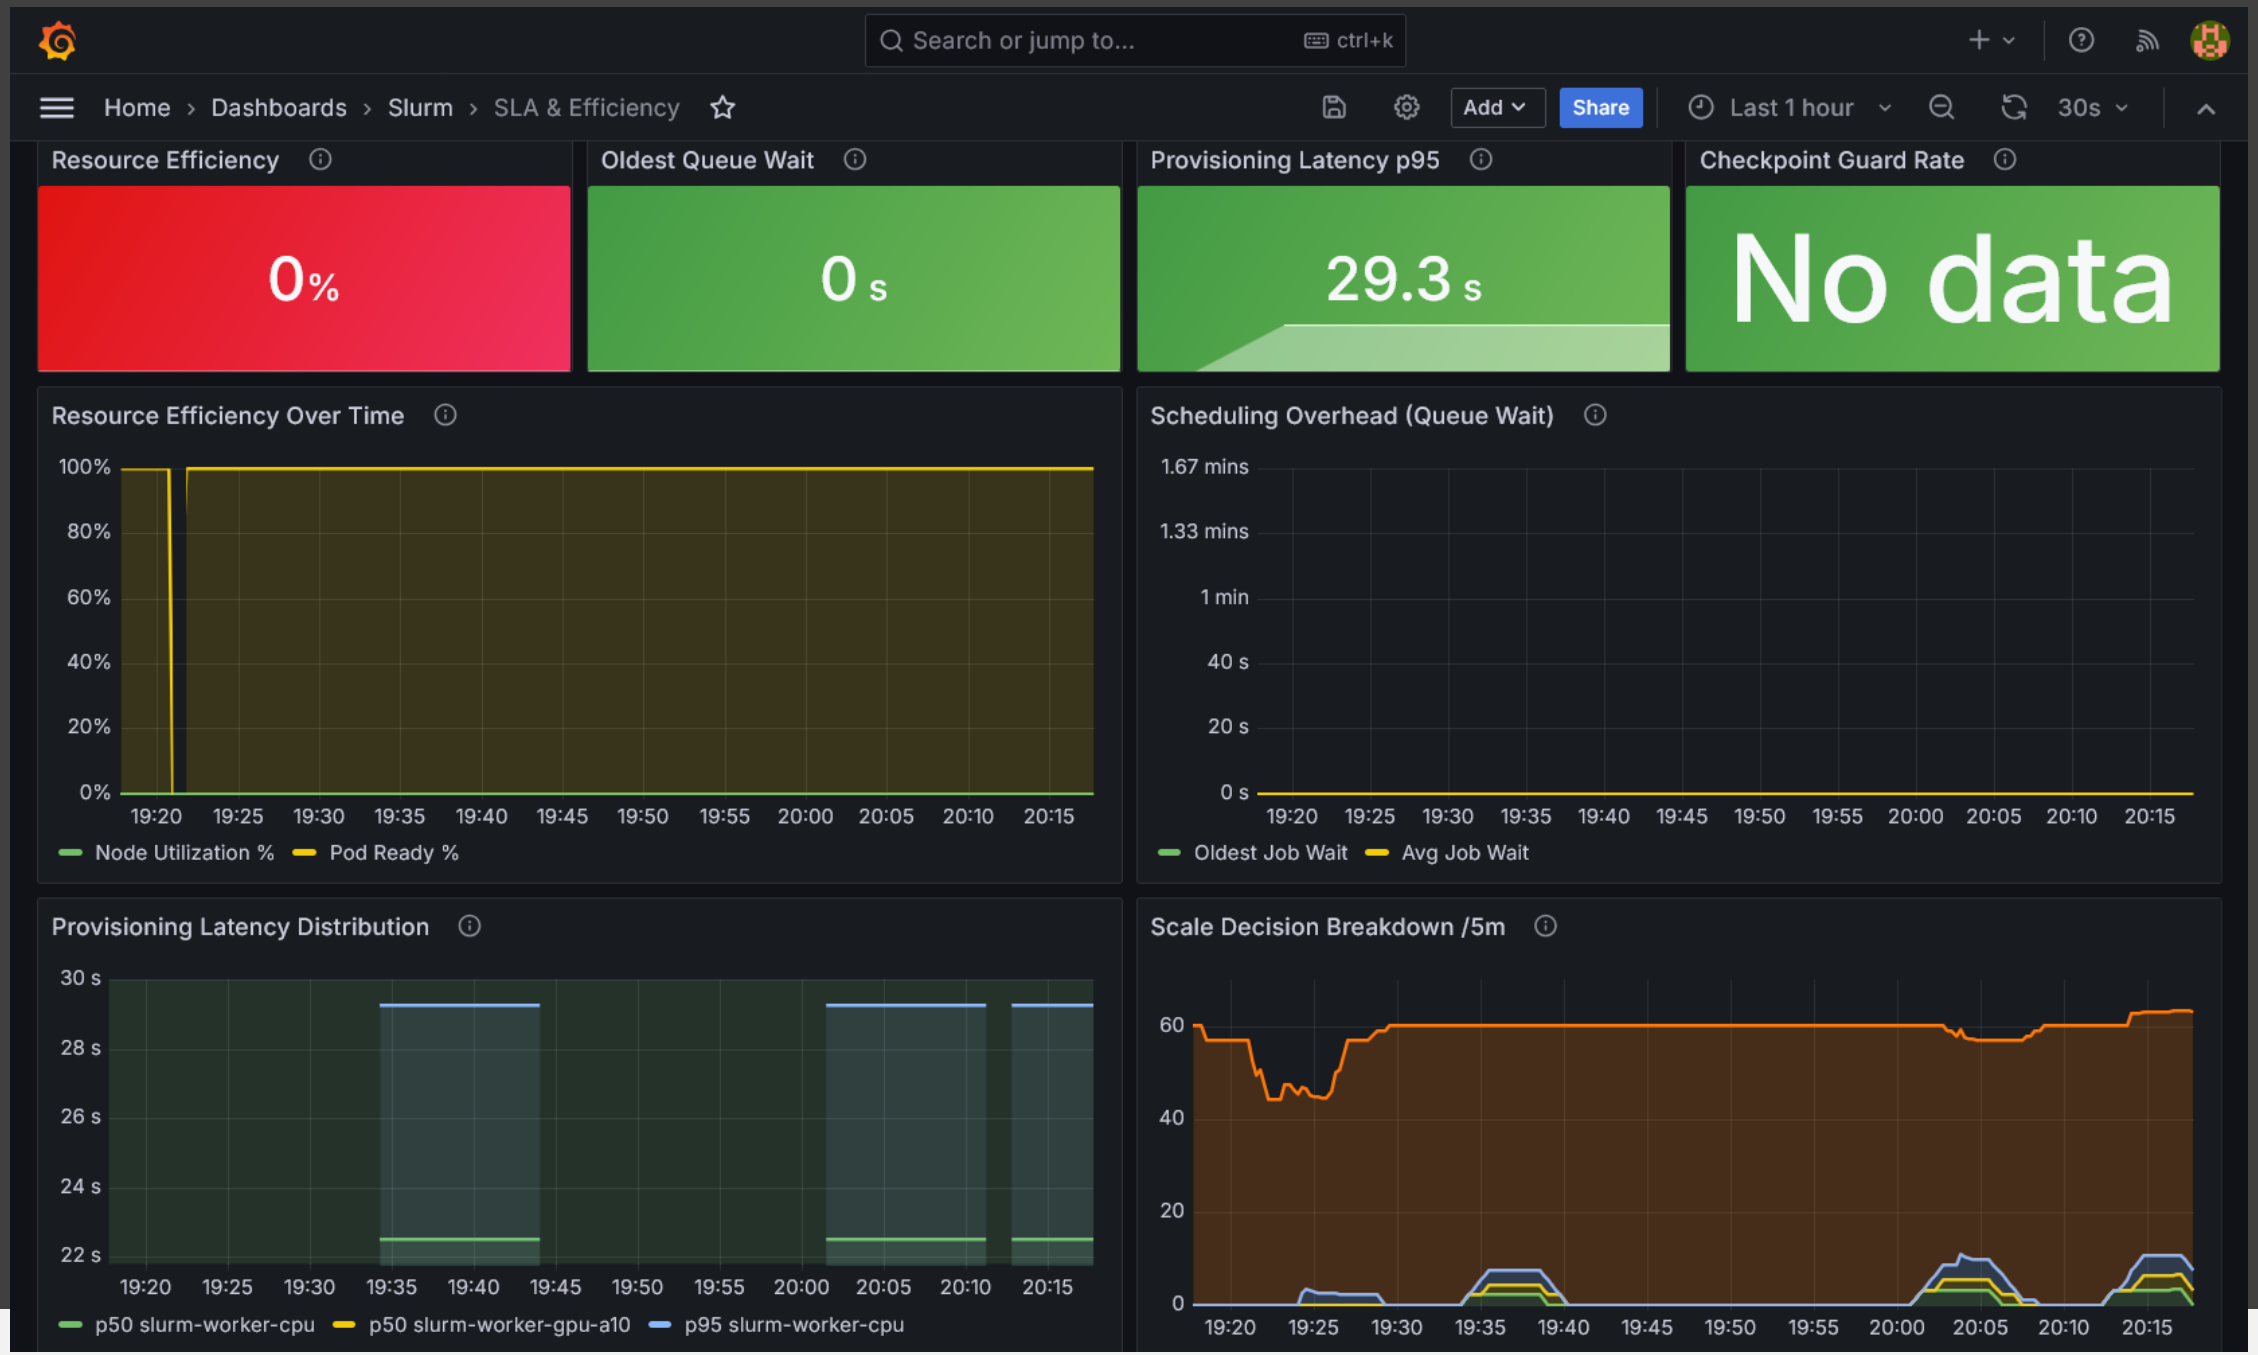
Search or jump to...
ctrl+k
Home › Dashboards › Slurm › SLA & Efficiency
Add
Share
Last 1 hour
30s
Resource Efficiency
0%
Oldest Queue Wait
0 s
Provisioning Latency p95
29.3 s
Checkpoint Guard Rate
No data
Resource Efficiency Over Time
100%
80%
60%
40%
20%
0%
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
Node Utilization %
Pod Ready %
Scheduling Overhead (Queue Wait)
1.67 mins
1.33 mins
1 min
40 s
20 s
0 s
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
Oldest Job Wait
Avg Job Wait
Provisioning Latency Distribution
30 s
28 s
26 s
24 s
22 s
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15
p50 slurm-worker-cpu
p50 slurm-worker-gpu-a10
p95 slurm-worker-cpu
Scale Decision Breakdown /5m
60
40
20
0
19:20 19:25 19:30 19:35 19:40 19:45 19:50 19:55 20:00 20:05 20:10 20:15

Networking

Network Flow

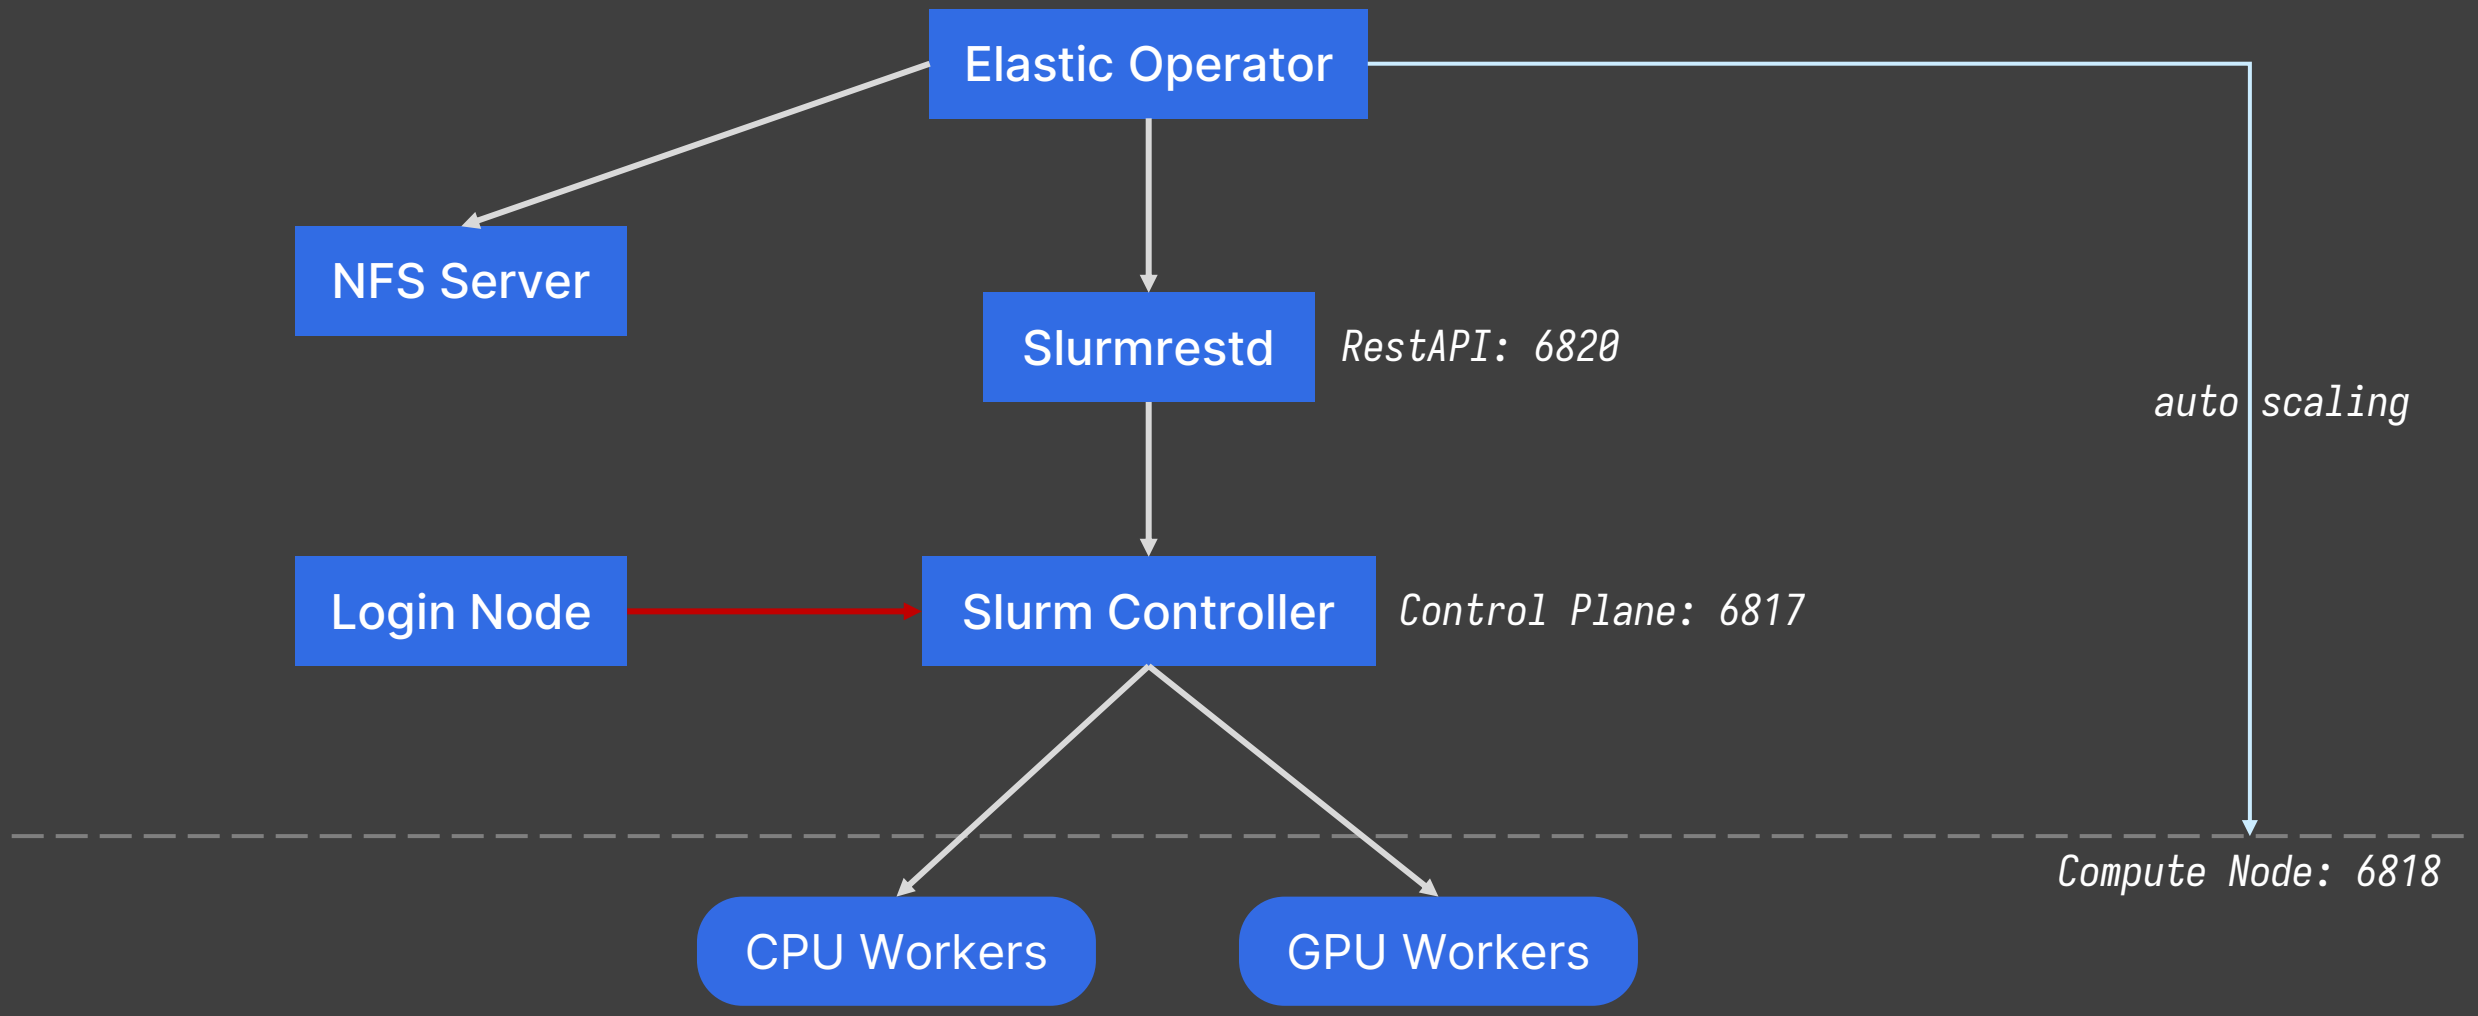

https://github.com/SoWiEee/Slurm-on-K8s-For-DDP/blob/main/docs/cluster.md

Future Work

Helm Chart

- 切分容器/服務，部署需要依序執行多支 bootstrap 腳本。Helm 讓整個系統可以一條指令完成：

```
helm install slurm-on-k8s ./chart \
  --set cluster.name=my-lab \
  --set pools.cpu.maxReplicas=8 \
  --set pools.gpuA10.maxReplicas=4 \
  --set monitoring.enabled=true \
  --set alertmanager.slack.webhookUrl="https://hooks.slack.com/..."
```

- 主要收益：dev/prod 只需一份 yaml，消除目前「改完 JSON 還要重新 render manifest」的步驟。

https://helm.sh/docs/topics/charts/

Distributed Tracing (1/2)

- 搜集應用程式內部與端到端請求相關的資料，以實現對整個系統的監控和分析。

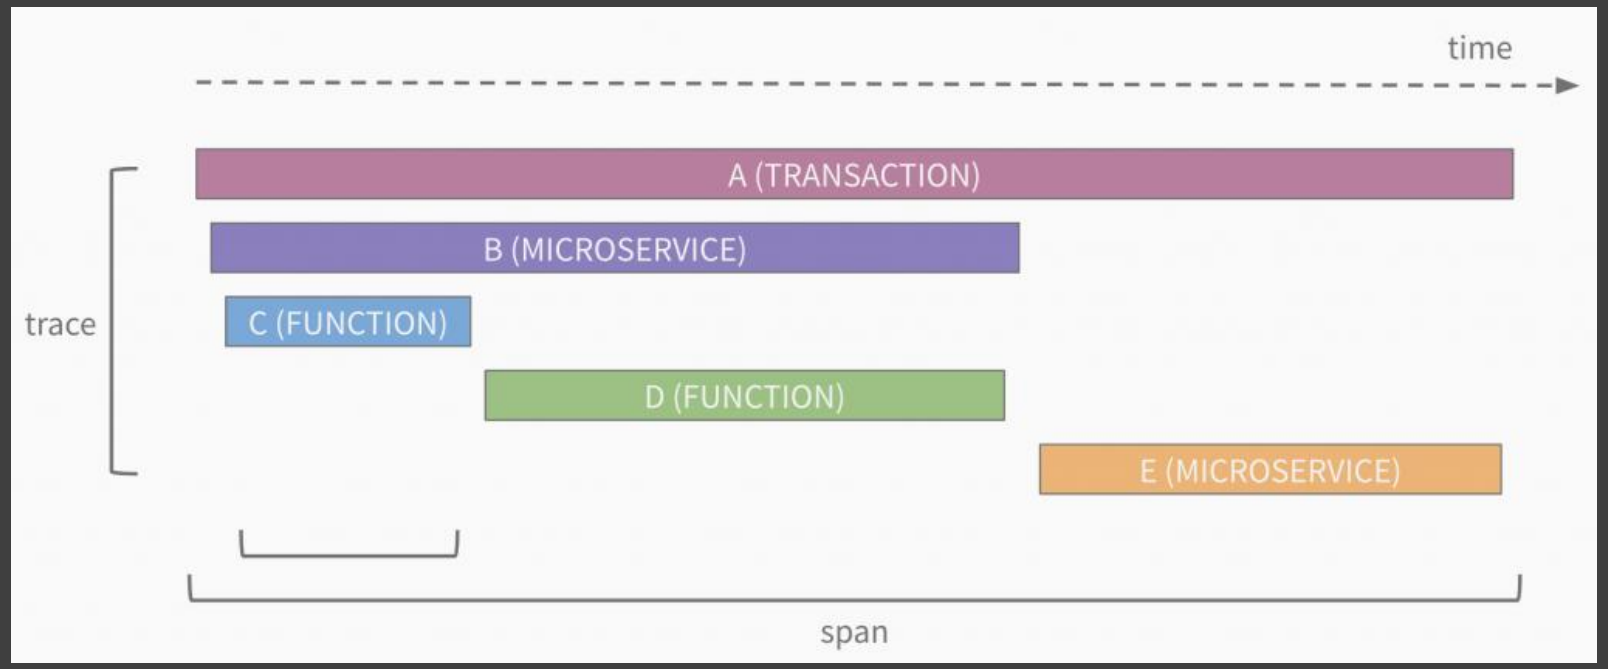

Distributed Tracing (2/2)

- 讓一個訓練 job 的完整生命週期變成一條可視化的 Trace：

```
[sbatch submit] → [pending in queue] → [scale-up decision]
  → [K8s provisioning] → [slurmd registration] → [DDP torchrun]
    → [checkpoint write] → [scale-down decision] → [job complete]
```

- 紀錄 job_id, pool, checkpoint_age 等屬性

(+) Tools：Jaeger / Grafana Tempo

https://grafana.com/oss/tempo/

High Availability (1/2)

- 企業服務越來越依賴網路系統，若系統一當機就可能造成營收損失或商譽危機，因此備援與 HA 是資訊系統設計不可忽視的一環。
- 系統在遭遇故障、維護或負載高峰時，仍保持服務不中斷。
  - 減少單點故障 (SPOF)
  - 提供故障轉移 (failover) 能力
  - 達到接近 7x24 小時無間斷的服務水準

High Availability (2/2)

- 目前只有一個 Operator，Pod 重啟會有 15~30 秒的決策空窗。
- Leader Election via K8s Lease（coordination.k8s.io/v1）：多個 Operator Pod 同時運行，只有 leader 執行 scaling loop
- Cooldown 狀態已透過 StatefulSet annotation 持久化，重新選主不會重置 cooldown
- 🎯 Zero-downtime Operator 滾動升級

QoS (1/4)

- 所有節點在同一個 partition，MaxTime=INFINITE
- 真實 HPC 叢集通常有：

```
PartitionName=interactive Nodes=cpu-[0-3] MaxTime=4:00:00 Priority=50
PartitionName=gpu-normal  Nodes=gpu-a10-[0-3] MaxTime=24:00:00 Priority=100 QOS=gpu-normal
PartitionName=gpu-preempt Nodes=gpu-h100-[0-3] MaxTime=INFINITE PreemptMode=REQUEUE
```

- 沒有 MaxTime 限制，代表一個壞掉的 job 可以永遠占用節點

https://github.com/SoWiEee/Slurm-on-K8s-For-DDP/blob/main/docs/review.md

QoS (2/4)

- 排程策略：沒有 Preemption 設定
- 若高優先度的緊急工作負載（例如 model serving 或緊急訓練）提交，無法搶佔已佔用資源的低優先度 job。
- 改進作法：

```
PreemptType=preempt/partition_prio
PreemptMode=REQUEUE    # 被搶佔的 job 重新排隊
# 或
PreemptMode=CHECKPOINT  # 被搶佔前先存 checkpoint
```

QoS (3/4)

- 排程策略：沒有 Gang Scheduling
  - DDP Job 需要**所有 rank 同時運行**，而 Slurm 預設是只要申請的節點有空就開始跑，剩餘的 rank 等待。
  - 在大型叢集會造成 Backfill fragmentation：部分 rank 已佔用 GPU，整個 job 仍無法開始，浪費資源。
- 解決方案：
  - Gang Scheduling (KEP-4671) @k8s v1.35

QoS (4/4)

- Backfill scheduler 有幾個重要參數目前是 Default

```
SchedulerType=sched/backfill
SchedulerParameters=bf_max_job_user=10,bf_max_job_test=500,bf_resolution=600
```

- 在 GPU 叢集中，若 backfill 時間解析度太大，scheduler 無法正確預測短時間內的 GPU 釋放，導致 backfill 效果差。

https://github.com/SoWiEee/Slurm-on-K8s-For-DDP/blob/main/docs/review.md

Security

The 4C's of Cloud Native Security

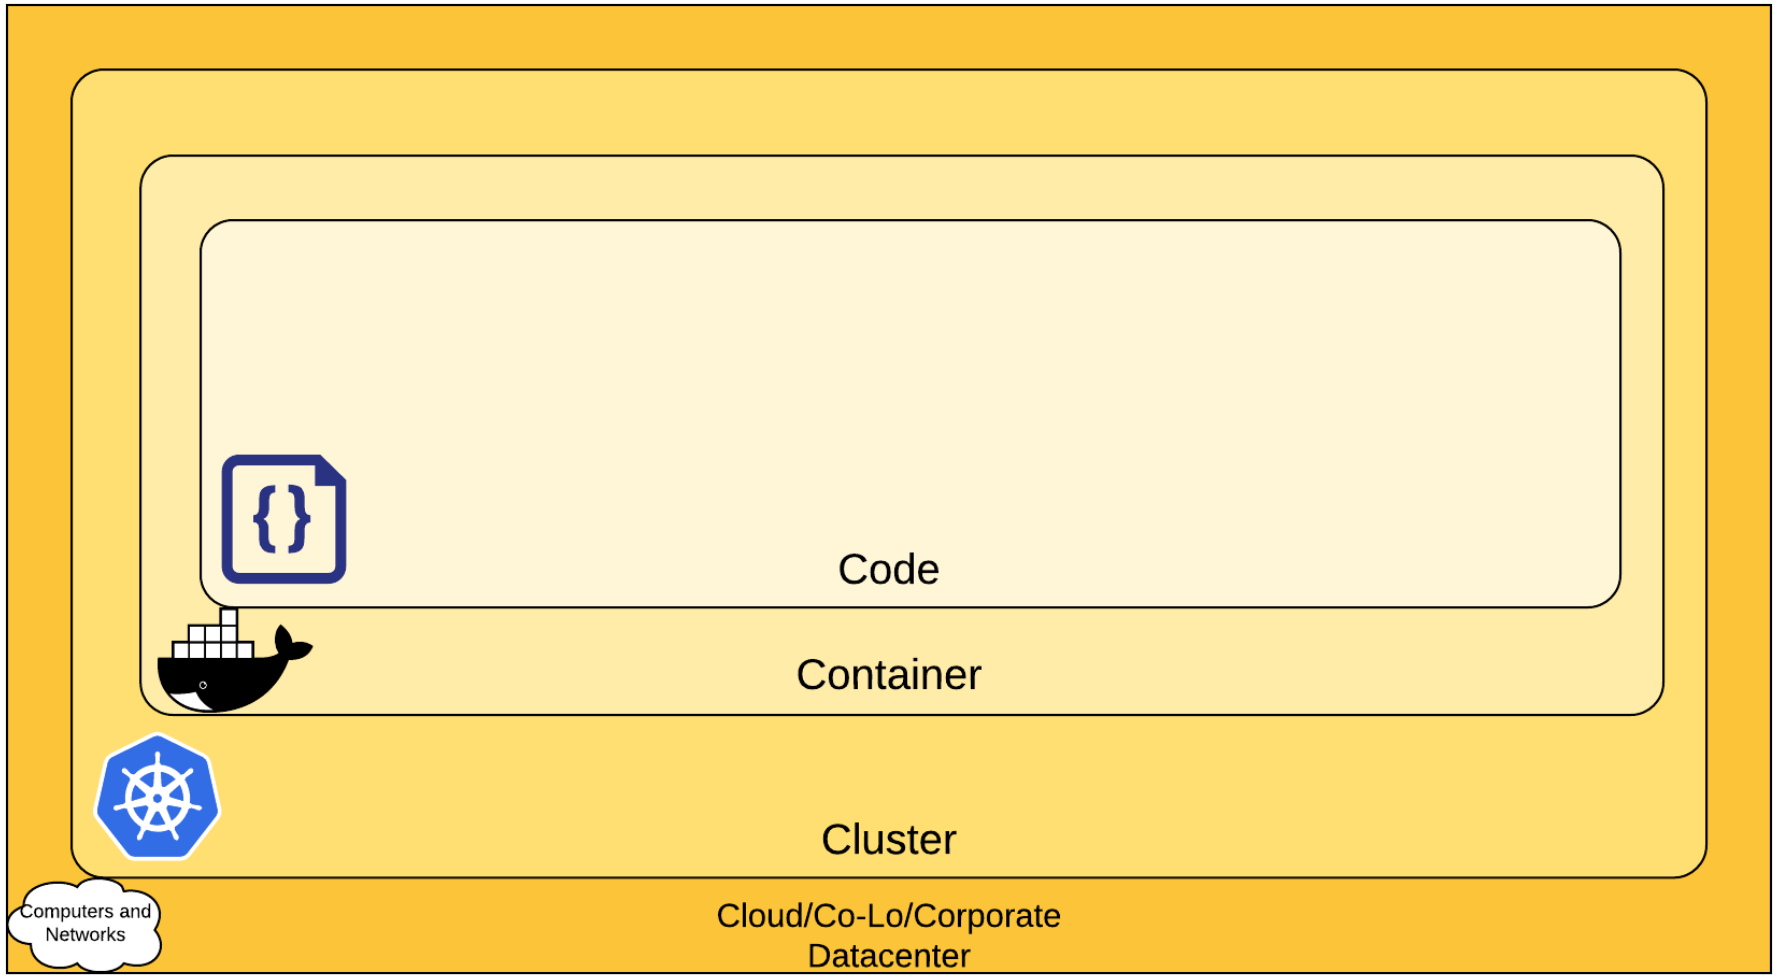

https://www.tigera.io/learn/guides/cloud-native-security/

Code Security

- 雖然應用程式原始碼的安全通常超出了 K8s 基礎設施的討論範圍，但它依然是整個雲端原生安全不可或缺的一環。
- 實施靜態/動態應用程式安全測試 (SAST / DAST)
- 定期掃描與更新第三方程式庫與相依套件
- 防範常見的應用程式漏洞 (OWASP Top 10)

Container Security

- 運行環境的權限設定，最小權限原則
- 容器內部軟體是否本身就有安全性漏洞
- Image 本身的數位簽章

Cluster Security

- 主要針對 K8s 叢集本身的防護
- 必須根據應用程式的攻擊面來配置安全策略：
  - RBAC/Auth
  - Secrets Management
  - Pod 安全規範
  - QoS & Resource limit
  - Network Policies
  - TLS 加密

Cloud Security

- 這是整個安全模型的地基，也是 Kubernetes 叢集的信任基礎
- 如果雲端層本身存在漏洞，或者設定不當，那麼建構在其上的所有元件都無法保證安全。
- 嚴格遵守各家雲端服務供應商（AWS, GCP, Azure）針對其環境所提出的基礎設施安全建議與最佳實踐。